

Resumo Analítico — Probabilidade e Estatística

Licenciatura em Engenharia Informática e de Computadores (LEIC)

Departamento de Matemática

Autores das apresentações: **C. Fernandes & P. Ramos**

7 Unidades Temáticas · 357 Slides · Resumo integral de conteúdos

Índice

1. Estatística Descritiva e Análise Exploratória de Dados
2. Teoria das Probabilidades
3. Variáveis Aleatórias e Modelos Discretos
4. Variáveis Aleatórias e Modelos Contínuos
5. Estimação por Intervalos de Confiança
6. Testes de Hipóteses
7. Correlação e Regressão Linear
8. Lista de Termos-Chave

Estatística Descritiva e Análise Exploratória de Dados

Contexto e Problema Central

Este módulo introduz os fundamentos da Estatística e os instrumentos para descrever, organizar e sintetizar conjuntos de dados reais, distinguindo a abordagem *descritiva* (caracterização da amostra) da abordagem de *inferência* (generalização à população).

Conceitos Fundamentais

Estatística Descritiva vs. Inferência Estatística

- **Estatística descritiva:** descreve propriedades de um conjunto de dados.
- **Inferência estatística:** generaliza os resultados da amostra à população.

População e Amostra

- **População:** conjunto de todos os indivíduos/objetos com características em comum; pode ser finita ou infinita.
- **Amostra:** subconjunto finito representativo da população; obtida por *amostragem*.

CRITÉRIOS DE UMA BOA AMOSTRA

Imparcialidade (todos os elementos têm igual oportunidade) · Representatividade (proporcional à população) · Tamanho suficiente para aproximar as características populacionais.

Tipos de Variáveis

Tipo	Subtipo	Descrição
Qualitativa	—	Não é possível atribuir unidade de medida (ex.: cor, país)
Quantitativa	Discreta	Valores numeráveis (ex.: nº de acidentes)
	Contínua	Qualquer valor num intervalo (ex.: temperatura)

Escalas de Medida

- **Binária:** dois estados possíveis.
- **Nominal:** mais de dois estados, sem ordem.
- **Ordinal:** estados ordenáveis, mas sem distâncias definidas.
- **Intervalar:** distâncias definidas, origem arbitrária (ex.: temperatura em °C).
- **Absoluta:** como intervalar mas com origem fixa em zero (ex.: massa).

Variáveis Qualitativas — Organização e Medidas

Distribuição de Frequências

- **Frequência absoluta (F_i):** número de vezes que cada categoria ocorre.

- **Frequência relativa ($f_i = F_i/n$):** proporção de cada categoria no total.

Representações gráficas: sectograma (gráfico circular) e diagrama de barras.

Moda (variáveis qualitativas)

A **moda (Mo)** é a categoria de maior frequência. Um conjunto pode ser: unimodal, bimodal, multimodal ou amodal.

Variáveis Quantitativas — Dados Não Agrupados

Procedimento inicial: ordenar a amostra por ordem crescente de grandeza.

Medidas de Tendência Central

Medida	Fórmula	Observação
Moda (Mo)	Valor mais frequente	Unimodal / bimodal / multimodal / amodal
Mediana (Me)	Quantil de ordem $p = 1/2$	Divide a amostra ao meio
Média ($\bar{x}$)	$\bar{x} = \sum x_i / n$	Sensível a outliers

Quantis

Dividem os dados em grupos com igual número de observações. Fórmula geral:

$$Q_p = (1-k) \cdot x(i) + k \cdot x(i+1)$$

onde $i = \lfloor np + 1 - p \rfloor$ e $k = np + 1 - p - i$ (com $0 < p < 1$)

- Quartis: $p = 1/4, 2/4, 3/4 \rightarrow 3$ quartis ($Q_1, Q_2=Me, Q_3$)
- Decis: 9 decis ($p = 1/10, \dots, 9/10$)
- Percentis: 99 percentis ($p = 1/100, \dots, 99/100$)

Outliers — Identificação

Dado o intervalo inter-quartis $IQ = Q_{3/4} - Q_{1/4}$:

Tipo	Barreira inferior	Barreira superior
Interna	$Q_{1/4} - 1,5 \cdot IQ$	$Q_{3/4} + 1,5 \cdot IQ$
Externa	$Q_{1/4} - 3 \cdot IQ$	$Q_{3/4} + 3 \cdot IQ$

- **Outlier moderado:** entre barreira interna e externa — aceite com suspeita.
- **Outlier extremo/severo:** além da barreira externa — deve ser investigado.

O **diagrama de extremos e quartis (boxplot)** representa visualmente: mínimo sem outlier (m), Q_1 , Me, Q_3 , máximo sem outlier (M), outliers moderados (○) e extremos (★).

Medidas de Dispersão

Medida	Fórmula	Interpretação
Amplitude total (R)	$R = \max\{x_i\} - \min\{x_i\}$	Diferença entre extremos

Intervalo inter-quartis (IQ)	$IQ = Q_{3/4} - Q_{1/4}$	Dispersão dos 50% centrais
Variância (s^2)	$s^2 = \Sigma(x_i - \bar{x})^2 / (n-1)$	Dispersão em unidades ²
Desvio padrão (s)	$s = \sqrt{s^2}$	Dispersão em unidades de X
Coefficiente de variação (cv)	$cv = s / \bar{x} \times 100\%$	Dispersão relativa, sem unidades

CRITÉRIOS DE VARIABILIDADE PELO COEFICIENTE DE VARIAÇÃO

$cv \leq 15\% \rightarrow$ variabilidade fraca | $15\% < cv < 30\% \rightarrow$ média | $cv \geq 30\% \rightarrow$ elevada.
 $cv > 50\%$ indica baixa representatividade da média.

Teoria das Probabilidades

Contexto e Problema Central

Este módulo formaliza os fundamentos matemáticos para quantificar a incerteza em experiências aleatórias, estabelecendo as bases para toda a inferência estatística subsequente.

Experiências e Espaço de Resultados

- **Experiência determinista:** resultado é conhecido à partida; sempre o mesmo em condições idênticas.
- **Experiência aleatória:** resultado não é conhecido à partida; conhece-se o conjunto de resultados possíveis.
- **Espaço de resultados (S, Ω ou U):** conjunto de todos os resultados possíveis.
- **Acontecimento:** subconjunto do espaço de resultados.

Tipos de Acontecimentos

- **Elementar:** contém exatamente um resultado.
- **Composto:** contém mais do que um resultado.
- **Certo (S):** contém todos os resultados.
- **Impossível (∅):** sem resultados.

Operações com Acontecimentos

Operação	Símbolo	Definição
Contrário	$\bar{A}$	Elementos de S que não pertencem a A
Reunião	$A \cup B$	A ou B se realizam
Interseção	$A \cap B$	A e B se realizam simultaneamente
Diferença	$A \setminus B = A\bar{B}$	A realiza-se sem B
Mutuamente exclusivos	$A \cap B = \emptyset$	Um exclui o outro

Propriedades: comutativa, associativa, distributiva, idempotência, leis de De Morgan.

Conceitos de Probabilidade

Conceito	Característica	Fórmula
Clássico (à priori)	Acontecimentos equiprováveis	$P[A] = N_A / N$
Frequencista (à posteriori)	Experiências repetidas	$P[A] = \lim(N \rightarrow \infty) N_A / N$
Subjetivo	Baseado em intuição/conhecimento pessoal	—

Axiomas da Teoria das Probabilidades (Kolmogorov)

- (i) $P[A_i] \geq 0, \quad \forall A_i \subseteq S$
- (ii) $P[S] = 1$
- (iii) Se $A_1, \dots, A_n$ são mutuamente exclusivos:
- $$P[A_1 \cup A_2 \cup \dots \cup A_n] = P[A_1] + P[A_2] + \dots + P[A_n]$$

Consequências dos Axiomas

- $P[\bar{A}] = 1 - P[A]$
- $P[\emptyset] = 0$
- $P[A \cup B] = P[A] + P[B] - P[A \cap B]$ (se $A \cap B \neq \emptyset$)
- $P[A \cup B \cup C] = P[A] + P[B] + P[C] - P[A \cap B] - P[A \cap C] - P[B \cap C] + P[A \cap B \cap C]$
- $0 \leq P[A] \leq 1, \forall A \subseteq S$

Probabilidades Condicionadas

$$P[A|B] = P[A \cap B] / P[B], \quad \text{para } P[B] > 0$$

Teorema do produto: $P[A \cap B] = P[B] \cdot P[A|B] = P[A] \cdot P[B|A]$

Acontecimentos Independentes

A e B são independentes se e só se $P[A \cap B] = P[A] \cdot P[B]$. Neste caso, $P[A|B] = P[A]$ e $P[B|A] = P[B]$.

DISTINÇÃO CRÍTICA

Dois acontecimentos com probabilidades não nulas

NÃO PODEM SER SIMULTANEAMENTE MUTUAMENTE EXCLUSIVOS E INDEPENDENTES

. Se são mutuamente exclusivos ($P[A \cap B] = 0$), não podem ser independentes ($P[A \cap B] \neq P[A] \cdot P[B] > 0$).

Partição e Teoremas Fundamentais

Partição

$A_1, A_2, \dots, A_n$ constituem uma partição de S se: (1) $A_1 \cup \dots \cup A_n = S$; (2) $A_i \cap A_j = \emptyset$ para $i \neq j$; (3) $P[A_i] > 0$ para todo i.

Teorema da Probabilidade Total

$$P[B] = \sum_i P[A_i] \cdot P[B|A_i]$$

Teorema de Bayes

$$P[A_j|B] = P[A_j] \cdot P[B|A_j] / \sum_i P[A_i] \cdot P[B|A_i]$$

O Teorema de Bayes permite "inverter" a probabilidade condicionada: a partir de $P[B|A_j]$ calcula-se $P[A_j|B]$.

Variáveis Aleatórias e Modelos Teóricos Unidimensionais Discretos

Contexto e Problema Central

Formaliza a noção de variável aleatória como função do espaço amostral para a reta real, e apresenta os principais modelos discretos com respectivas funções de massa de probabilidade, parâmetros e aplicações.

Variável Aleatória

Função $X: S \rightarrow \mathbb{R}$ que associa a cada resultado $s \in S$ um valor real $x = X(s)$.

- **Discreta:** toma valores num conjunto finito ou infinito numerável (inteiros).
- **Contínua:** toma qualquer valor num intervalo (reais).

Função Massa de Probabilidade (FMP)

$$\begin{aligned} f(x) &= P[X = x_i] = p_i && \text{para } x = x_i \\ f(x) &= 0 && \text{para } x \neq \text{qualquer } x_i \end{aligned}$$

Propriedades: $f(x) \geq 0$ e $\sum f(x_i) = 1$.

Função de Distribuição (FD)

$$F(x) = P[X \leq x] = \sum_{\{x_i \leq x\}} f(x_i)$$

Propriedades: domínio $\mathbb{R}$; $0 \leq F(x) \leq 1$; não-decrescente; contínua à direita.

Parâmetros das Variáveis Aleatórias Discretas

Parâmetro	Fórmula	Unidades
Valor médio / Esperança (μ)	$E[X] = \sum x_i \cdot f(x_i)$	Unidades de X
Variância (σ^2)	$\text{Var}[X] = E[X^2] - (E[X])^2$	Unidades ² de X
Desvio padrão (σ)	$\sigma = \sqrt{\text{Var}[X]}$	Unidades de X
Coef. variação (Cv)	$\text{Cv} = \sigma / \mu \times 100\%$	Adimensional (%)

Propriedades: $E[kX] = k \cdot E[X]$; $\text{Var}[kX] = k^2 \cdot \text{Var}[X]$; $\text{Var}[X \pm Y] = \text{Var}[X] + \text{Var}[Y]$ (se independentes).

Modelos Teóricos Discretos

Distribuição de Bernoulli — $X \sim \text{Bernoulli}(p)$

Prova com dois resultados: sucesso (prob. p) e insucesso (prob. $q = 1-p$).

Parâmetro

Fórmula

$E[X]$	p
$\text{Var}[X]$	$p(1-p) = pq$

Distribuição Binomial — $X \sim b(n, p)$

Número de sucessos em n provas de Bernoulli **independentes** com prob. de sucesso constante p .

$$f(x) = C(n, x) \cdot p^x \cdot (1-p)^{n-x}, \quad x = 0, 1, \dots, n$$

Parâmetro	Fórmula
$E[X]$	np
$\text{Var}[X]$	$np(1-p) = npq$

Distribuição Hipergeométrica — $X \sim h(N, n, K)$

Número de sucessos em n extracções **sem reposição** de uma população finita N com K elementos com a característica pretendida.

$$f(x) = [C(K, x) \cdot C(N-K, n-x)] / C(N, n)$$

$$x = \max\{0, n-N+K\}, \dots, \min\{K, n\}$$

Parâmetro	Fórmula
$E[X]$	$n \cdot p$ (com $p = K/N$)
$\text{Var}[X]$	$n \cdot p \cdot (1-p) \cdot (N-n)/(N-1)$

APROXIMAÇÃO BINOMIAL

Quando $n < N/10$, a distribuição hipergeométrica pode ser aproximada pela binomial com $p = K/N$.

Distribuição de Poisson — $X \sim P(\lambda)$

Número de ocorrências de um acontecimento num intervalo temporal ou região espacial, num processo de Poisson (ocorrências independentes em intervalos disjuntos, probabilidade proporcional à amplitude).

$$f(x) = \lambda^x \cdot e^{-\lambda} / x!, \quad x = 0, 1, 2, \dots \quad (\lambda > 0)$$

Parâmetro	Fórmula
$E[X]$	λ
$\text{Var}[X]$	λ

ADITIVIDADE DE POISSON

Se $X_1, \dots, X_n$ são independentes com $X_i \sim P(\lambda_i)$, então $\sum X_i \sim P(\sum \lambda_i)$.

Variáveis Aleatórias e Modelos Teóricos Unidimensionais Contínuos

Contexto e Problema Central

Generalização para variáveis contínuas, com ênfase nos modelos Exponencial, Uniforme e Normal (incluindo o Teorema do Limite Central e aproximações às distribuições discretas).

Função Densidade de Probabilidade (FDP)

$$P[a \leq X \leq b] = \int_a^b f(x) dx$$

Propriedades: $f(x) \geq 0$ e $\int_{-\infty}^{+\infty} f(x) dx = 1$.

Para variáveis contínuas, $P[X = x_0] = 0$.

Função de Distribuição Acumulada

$$F(x) = P[X \leq x] = \int_{-\infty}^x f(s) ds$$

Cálculo de probabilidades:

$$P[X > x] = 1 - F(x)$$

$$P[x_1 \leq X \leq x_2] = F(x_2) - F(x_1)$$

Parâmetros

Parâmetro	Fórmula (contínuo)
$E[X]$	$\int_{-\infty}^{+\infty} x \cdot f(x) dx$
$\text{Var}[X]$	$\int_{-\infty}^{+\infty} (x-\mu)^2 \cdot f(x) dx = E[X^2] - (E[X])^2$
σ	$\sqrt{\text{Var}[X]}$
Cv	$\sigma/ \mu \times 100\%$

Modelos Teóricos Contínuos

Distribuição Exponencial — $X \sim \exp(\lambda)$

Modela o tempo/distância até à 1ª ocorrência ou entre duas ocorrências consecutivas num processo de Poisson.

$$f(x) = \lambda \cdot e^{-\lambda x}, \quad x > 0$$

$$F(x) = 1 - e^{-\lambda x}, \quad x > 0$$

Parâmetro

Fórmula

$E[X]$	$1/\lambda$
$\text{Var}[X]$	$1/\lambda^2$

PROPRIEDADE DE FALTA DE MEMÓRIA

$P[X \leq a+b \mid X > a] = P[X < b]$ — o componente não "envelhece".

Distribuição Uniforme — $X \sim U(a, b)$

Qualquer subintervalo com a mesma amplitude tem a mesma probabilidade. Também chamada distribuição rectangular.

$$f(x) = 1/(b-a), \quad a \leq x \leq b$$

$$F(x) = (x-a)/(b-a), \quad a \leq x \leq b$$

Parâmetro

Fórmula

$E[X]$	$(a+b)/2$
$\text{Var}[X]$	$(b-a)^2/12$

Área entre $\mu-\sigma$ e $\mu+\sigma \approx 57,74\%$.

Distribuição Normal — $X \sim N(\mu, \sigma)$

Modelo mais relevante em Estatística, adequado para muitos fenómenos reais (características humanas, erros de medição, etc.).

$$f(x) = (1/(\sigma\sqrt{2\pi})) \cdot \exp\{-(1/2) \cdot ((x-\mu)/\sigma)^2\}, \quad -\infty < x < +\infty$$

A curva tem forma de sino, simétrica em torno de $x = \mu$; pontos de inflexão em $x = \mu \pm \sigma$.

PROPRIEDADES NUMÉRICAS DA NORMAL

$$P[\mu-\sigma \leq X \leq \mu+\sigma] \approx 68,26\%$$

$$P[\mu-2\sigma \leq X \leq \mu+2\sigma] \approx 95,44\%$$

$$P[\mu-3\sigma \leq X \leq \mu+3\sigma] \approx 99,74\%$$

Normalização (Estandardização)

Conversão para normal padrão $Z \sim N(0,1)$:

$$Z = (X - \mu) / \sigma \rightarrow Z \sim N(0,1)$$

$$E[Z] = 0, \quad \text{Var}[Z] = 1$$

Cálculo de probabilidades usando tabela da $\Phi(z)$:

$$P[a \leq X \leq b] = \Phi((b-\mu)/\sigma) - \Phi((a-\mu)/\sigma)$$

Simetria: $\Phi(-z) = 1 - \Phi(z)$

Aditividade da Normal

Se $X_i \sim N(\mu_i, \sigma_i)$ independentes, então $Y = \sum a_i X_i \sim N(\sum a_i \mu_i, \sqrt{(\sum a_i^2 \sigma_i^2)})$.

Teorema do Limite Central (TLC)

ENUNCIADO

Seja $X_1, \dots, X_n$ uma amostra i.i.d. com $E[X_i] = \mu$ e $\text{Var}[X_i] = \sigma^2$, e $Y = \sum X_i$. Para $n > 30$:

$$Z = (Y - n\mu) / \sqrt{n\sigma^2} \approx N(0, 1)$$

Equivalentemente para a média amostral: $Z = (\bar{X} - \mu) / (\sigma/\sqrt{n}) \approx N(0, 1)$

Quando usar o TLC: amostra com $n > 30$; variáveis i.i.d.; população não-normal; cálculo de probabilidades sobre Y ou $\bar{X}$.

Correção de Continuidade (variáveis discretas → normal)

$$P[X = x] \approx P[x - 0,5 \leq X \leq x + 0,5]$$

$$P[x_1 \leq X \leq x_2] \approx P[x_1 - 0,5 \leq X \leq x_2 + 0,5]$$

$$P[X \leq x] \approx P[X \leq x + 0,5]$$

$$P[X \geq x] \approx P[X \geq x - 0,5]$$

Aproximações à Normal

- **Binomial → Normal:** quando $n > 20$ e $np \geq 5 \rightarrow (X - np) / \sqrt{np(1-p)} \approx N(0, 1)$
- **Poisson → Normal:** quando $\lambda > 20 \rightarrow (X - \lambda) / \sqrt{\lambda} \approx N(0, 1)$

Estimação por Intervalos de Confiança

Contexto e Problema Central

A estimação por intervalos é um dos pilares da inferência estatística: em vez de estimar um parâmetro com um único valor (estimação pontual), constrói-se um intervalo que contém o valor verdadeiro do parâmetro com uma dada probabilidade.

Terminologia Fundamental

Conceito	Definição	Exemplos
Parâmetro	Característica da população, valor fixo mas desconhecido	μ, σ^2, p
Estatística / Estimador	Função de uma amostra aleatória (variável aleatória)	$\bar{X}, S^2, \hat{P}$
Estimativa	Valor assumido pelo estimador para uma amostra concreta	$\bar{x}, s^2, \hat{p}$

Distribuições Amostrais

Distribuição	Notação	Características
Normal reduzida	$Z \sim N(0,1)$	Simétrica; $\mu=0, \sigma^2=1$; Z pode tomar qualquer real
t-Student	$T \sim t_n$	Simétrica; $\mu=0$ ($v>1$); $\sigma^2=v/(v-2)$ ($v>2$); caudas mais pesadas que N
Qui-quadrado	$X \sim \chi^2_n$	Assimétrica positiva; só valores ≥ 0 ; $\mu=v, \sigma^2=2v$
F-Snedecor	$X \sim F_{n1;n2}$	Assimétrica positiva; só valores ≥ 0 ; $F_{n1;n2;p} = 1/F_{n2;n1;1-p}$

Todas estas distribuições estão tabeladas e são usadas conforme o parâmetro a estimar e o conhecimento sobre a população.

Intervalo de Confiança

Um **intervalo de confiança aleatório** $[\hat{\theta}_1, \hat{\theta}_2]$ verifica:

$$P[\hat{\theta}_1 < \theta < \hat{\theta}_2] = 1 - \alpha$$

- **$1 - \alpha$** : nível de confiança (probabilidade do IC conter θ).
- **α** : nível de significância (probabilidade do IC não conter θ).

O **intervalo de confiança determinista** é obtido substituindo as estatísticas pelos valores da amostra observada.

INTERPRETAÇÃO PRÁTICA DO NÍVEL DE CONFIANÇA (EXEMPLO 95%)

Se se seleccionassem 100 amostras diferentes de tamanho n e se construísse um IC de 95% para cada uma, **95 DESSES INTERVALOS**

conteriam efetivamente o parâmetro populacional θ .

Escolhas Típicas de Nível de Confiança

90%, 95%, 99% — equilíbrio entre precisão (amplitude do IC) e confiabilidade (nível de confiança). Para amostra fixa, maior confiança $\rightarrow$ maior amplitude.

Distribuição da Variável Fulcral para cada caso

Distribuição fulcral	Probabilidade
Normal Z	$P[-Z_{1-\alpha/2} < VF < Z_{1-\alpha/2}] = 1-\alpha$
t-Student t_{n-1}	$P[-t_{n-1;1-\alpha/2} < VF < t_{n-1;1-\alpha/2}] = 1-\alpha$
Qui-quadrado χ^2_{n-1}	$P[\chi^2_{n-1;\alpha/2} < VF < \chi^2_{n-1;1-\alpha/2}] = 1-\alpha$
F-Snedecor	$P[F_{n1-1;n2-1;\alpha/2} < VF < F_{n1-1;n2-1;1-\alpha/2}] = 1-\alpha$

🔧 Passos para Construir um Intervalo de Confiança

1. Identificar o parâmetro a estimar.
2. Identificar o tipo de população.
3. Escolher o nível de confiança ($1-\alpha$).
4. Estabelecer o tamanho da amostra n .
5. Escolher a variável fulcral (pelo quadro resumo) e a sua distribuição amostral.
6. Construir o intervalo de confiança aleatório a partir da variável fulcral.
7. Determinar os extremos com os valores da amostra $\rightarrow$ IC determinista.
8. Apresentar uma conclusão.

Margem de Erro

Para ICs simétricos em torno da estatística ($\bar{X}$ ou $\hat{P}$):

$$E = \text{Amplitude do IC} / 2$$

Testes de Hipóteses

Contexto e Problema Central

Metodologia estatística para tomar decisões acerca dos parâmetros populacionais com base em amostras, avaliando se a evidência empírica é suficiente para rejeitar uma afirmação pré-estabelecida.

Elementos Básicos de um Teste Paramétrico

- **Hipótese nula (H₀):** afirmação sobre o parâmetro que contém a condição de igualdade. Formas: $\theta = \theta_0$, $\theta \leq \theta_0$, $\theta \geq \theta_0$. O teste é realizado supondo $\theta = \theta_0$.
- **Hipótese alternativa (H₁):** $\theta \neq \theta_0$ (bilateral), $\theta < \theta_0$ (unilateral esq.), $\theta > \theta_0$ (unilateral dir.).
- **Estatística de teste:** estimador do parâmetro; o seu valor determina a conclusão.
- **Regra de decisão:** rejeitar H₀ se a estatística de teste $\in$ região crítica.

Tipos de Teste

Tipo	H ₀	H ₁	Regiões críticas
Bilateral	$\theta = \theta_0$	$\theta \neq \theta_0$	Dois extremos: $\alpha/2$ em cada cauda
Unilateral direita	$\theta \leq \theta_0$	$\theta > \theta_0$	Cauda direita: α
Unilateral esquerda	$\theta \geq \theta_0$	$\theta < \theta_0$	Cauda esquerda: α

🔗 Passos para Realizar um Teste Paramétrico

1. Identificar o parâmetro a testar.
2. Especificar H₀ (com condição de igualdade) e H₁ (que condiciona o tipo de teste).
3. Identificar o tipo de população.
4. Escolher o nível de significância α (tipicamente 0,05 ou 0,01).
5. Estabelecer o tamanho da amostra n.
6. Pelo quadro resumo, identificar a estatística de teste e a sua distribuição amostral.
7. Determinar as regiões crítica e de aceitação, e o valor da estatística de teste.
8. Decisão: rejeitar H₀ se valor da estatística $\in$ região crítica; caso contrário, não rejeitar H₀.

p-value (Valor p)

O *p-value* é o **menor nível de significância α a partir do qual se começa a rejeitar H₀**. Regra: se $\alpha \geq p\text{-value} \rightarrow$ rejeitar H₀.

Tipo de teste	p-value
Bilateral (Z ou T)	$2 \times P[T \geq V.E.T.]$

Bilateral (χ^2 ou F)	$2 \times \min\{P[\chi^2 \leq \text{V.E.T.}]; P[\chi^2 \geq \text{V.E.T.}]\}$
Unilateral direita	$P[T \geq \text{V.E.T.}]$
Unilateral esquerda	$P[T \leq \text{V.E.T.}]$

Erros de Inferência

	Ho verdadeira	Ho falsa
Rejeitar Ho	Erro tipo I (probabilidade $\leq \alpha$)	Decisão correta
Não rejeitar Ho	Decisão correta	Erro tipo II (probabilidade $= \beta$)

- **Potência do teste:** $1 - \beta = P[\text{rejeitar } H_0 \mid H_0 \text{ falsa}]$.
- Para α fixo: aumentar $n \rightarrow$ diminuir β .
- Para n fixo: diminuir $\alpha \rightarrow$ aumentar β (e vice-versa).
- **Para reduzir α e β simultaneamente: aumentar n .**

Testes de Aderência (Não Paramétricos)

Testam se os dados provêm de uma população com determinada distribuição (geralmente Normal — pressuposto essencial para a maioria dos testes paramétricos clássicos).

H_0 : A amostra provém de uma população com distribuição Normal

H_1 : A amostra provém de uma população com distribuição diferente da Normal

Teste de Lilliefors-Kolmogorov-Smirnov

Estatística de teste $D = \max(D^+, D^-)$, onde:

$D^+ = \sup |F(x(i)) - S_n(x(i))|$ (diferença entre FD normal e empírica)

$D^- = \sup |F(x(i)) - S_n(x(i-1))|$

$S_n(x(i)) = i/n$ (função distribuição empírica)

Procedimento: ordenar amostra; calcular $z(i) = (x(i) - \bar{x})/s$; usar tabela de Lilliefors; rejeitar H_0 se $D_{\text{obs}} \geq D_{\text{crítico}}; \alpha$ ou se $\alpha \geq p\text{-value}$.

Teste de Shapiro-Wilk

Estatística de teste:

$W = b^2 / S^2$ onde $b = \sum a_i x(i)$ e $S^2 = \sum (x(i) - \bar{x})^2$

Os coeficientes a_i são tabelados (Shapiro & Wilk, 1965). Rejeitar H_0 se $W_{\text{obs}} \leq W_{\text{crítico}}; \alpha$.

🔗 Passos para Teste de Aderência

1. Especificar H_0 e H_1 .
2. Escolher o nível de significância α .
3. Estabelecer o tamanho da amostra.

4. Determinar o valor da estatística de teste e o valor crítico tabelado.
5. Decisão: rejeitar H_0 ou não rejeitar H_0 .

Correlação e Regressão Linear

Contexto e Problema Central

Estabelecer e quantificar relações matemáticas entre variáveis, permitindo prever o comportamento de uma variável (dependente, Y) a partir de outra (independente, x).

Diagrama de Dispersão

Representação gráfica dos pares observados (x_i, y_i) . Permite identificar a existência, direção (positiva/negativa), intensidade da correlação, e o tipo de relação (linear ou não linear).

Covariância Linear Amostral

$$\text{cov}[x, y] = \sum_i (x_i - \bar{x})(y_i - \bar{y}) / (n-1) = s_{xy} / (n-1)$$

Onde $s_{xy} = \sum x_i y_i - n\bar{x}\bar{y}$ é a **soma cruzada**.

- $\text{cov} > 0$: relação linear positiva
- $\text{cov} < 0$: relação linear negativa
- $\text{cov} = 0$: sem relação linear (pode existir relação não-linear)

Limitação: o valor da covariância depende das unidades de medida.

Coefficiente de Correlação Linear Amostral (r)

$$r = \text{cov}[x, y] / (s_x \cdot s_y) = s_{xy} / \sqrt{s_{xx} \cdot s_{yy}}, \quad \text{com } -1 \leq r \leq 1$$

Onde $s_{xx} = \sum (x_i - \bar{x})^2$ e $s_{yy} = \sum (y_i - \bar{y})^2$. Não depende das unidades de medida.

Valor de r	Interpretação
$r = +1$	Correlação linear positiva perfeita
$r = -1$	Correlação linear negativa perfeita
$r = 0$	Sem correlação linear
$ r \geq 0,7$	Correlação aceitável

CRITÉRIOS EM ENGENHARIA QUÍMICA (REFERÊNCIA DO MATERIAL)

$r = 0,9 \rightarrow$ aceitável | $r = 0,99 \rightarrow$ bom | $r = 0,999 \rightarrow$ muito bom

Regressão Linear Simples

Modelo: $Y = \beta_0 + \beta_1 x + E$, onde $E \sim N(0; \sigma)$ são os erros.

Método dos Mínimos Quadrados

Minimiza a soma dos quadrados dos erros ($SQE = \sum e_i^2$). Estimativas:

$$b = s_{xy} / s_{xx} = \text{cov}[x, y] / s^2_x \quad (\text{declive})$$

$$a = \bar{y} - b \cdot \bar{x} \quad (\text{ordenada na origem})$$

Recta ajustada: $\hat{y} = a + b \cdot x$

Interpretação: b é a variação de y por unidade de x; a é o valor de y quando x = 0.

Decomposição da Variabilidade

Componente	Fórmula	Significado
SQT (Total)	$\sum (y_i - \bar{y})^2 = s_{yy}$	Variabilidade total de Y
SQE (Erros)	$\sum (y_i - \hat{y}_i)^2 = s_{yy} - s^2_{xy}/s_{xx}$	Variabilidade não explicada
SQR (Regressão)	$\sum (\hat{y}_i - \bar{y})^2 = s^2_{xy}/s_{xx}$	Variabilidade explicada pela regressão

$$SQT = SQE + SQR$$

Coeficiente de Determinação (r^2)

$$r^2 = SQR/SQT = 1 - SQE/SQT = s^2_{xy} / (s_{xx} \cdot s_{yy}), \quad 0 \leq r^2 \leq 1$$

Percentagem da variabilidade de Y explicada por x. $r^2 = 1 \rightarrow$ ajuste perfeito; $r^2 = 0 \rightarrow$ ajuste sem utilidade. r^2 é o quadrado do coeficiente de correlação.

Pressupostos do Modelo e Inferência

Pressupostos sobre os Erros

- Valor esperado nulo: $E[E_i] = 0$
- Variância constante (homocedasticidade)
- Independência mútua
- Normalidade: $E_i \sim N(0; \sigma)$

A verificação é feita via análise de resíduos: $e_i = y_i - \hat{y}_i$. O gráfico de resíduos deve mostrar dispersão aleatória em torno de zero.

Estimadores dos Parâmetros

Parâmetro	Estimador	Estimativa
β_0 (ord. origem)	A	$a = \bar{y} - b \cdot \bar{x}$
β_1 (declive)	B	$b = s_{xy}/s_{xx}$
Y_0 (previsão em x_0)	$\hat{Y}_0$	$\hat{y}_0 = a + b \cdot x_0$

Variância dos Resíduos

$$s^2_{y \cdot x} = SQE / (n-2) = (s_{yy} - b \cdot s_{xy}) / (n-2) \quad [\text{com } n-2 \text{ graus de liberdade}]$$

Distribuições das Estatísticas de Teste

Para β_0 : $(A - \beta_0) / (s_y \cdot x \cdot \sqrt{1/n + x^2/s_{xx}}) \sim t_{\{n-2\}}$

Para β_1 : $(B - \beta_1) / (s_y \cdot x / \sqrt{s_{xx}}) \sim t_{\{n-2\}}$

Para Y_0 : $(\hat{Y}_0 - Y_0) / (s_y \cdot x \cdot \sqrt{1 + 1/n + (x_0 - \bar{x})^2/S_{xx}}) \sim t_{\{n-2\}}$

🔗 Passos para Intervalo de Confiança (Regressão)

1. Identificar o parâmetro a estimar (β_0 , β_1 ou Y_0).
2. Escolher o nível de confiança.
3. Estabelecer o tamanho da amostra.
4. Pelo quadro resumo, identificar a variável fulcral e distribuição.
5. Construir o IC aleatório.
6. Determinar os extremos com os valores observados → IC determinista.
7. Apresentar conclusão.

🔗 Passos para Teste de Hipóteses (Regressão)

1. Identificar o parâmetro a testar.
2. Especificar H_0 (com igualdade) e H_1 (que condiciona o tipo de teste).
3. Escolher o nível de significância α .
4. Estabelecer o tamanho da amostra.
5. Identificar estatística de teste e distribuição.
6. Determinar regiões crítica/aceitação e valor da estatística.
7. Decisão: rejeitar H_0 se V.E.T. $\in$ região crítica.

p-value na Regressão

Bilateral: $p\text{-value} = 2 \times P[T \geq |V.E.T.|]$

Unilateral direita: $p\text{-value} = P[T \geq V.E.T.]$

Unilateral esquerda: $p\text{-value} = P[T \leq V.E.T.]$

Lista de Termos-Chave

Amostra

Subconjunto finito representativo da população.

Amplitude total (R)

Diferença entre o maior e menor valor observado.

Axiomas de Kolmogorov

Base axiomática da teoria das probabilidades.

Bernoulli

Experiência com dois resultados: sucesso (p) e insucesso (q).

Binomial

Número de sucessos em n provas independentes com p constante.

Boxplot

Diagrama de extremos e quartis; identifica outliers.

Coefficiente de determinação (r^2)

% de variabilidade de Y explicada por x na regressão.

Coefficiente de variação (cv/Cv)

Desvio padrão/média $\times 100\%$; medida relativa de dispersão.

Correção de continuidade

Ajuste $\pm 0,5$ ao aproximar discreta $\rightarrow$ normal.

Correlação linear (r)

Grau de associação linear entre duas variáveis; $-1 \leq r \leq 1$.

Covariância

Medida de associação linear dependente das unidades.

Distribuição amostral

Distribuição de uma estatística calculada a partir de amostras.

Distribuição exponencial

Tempo entre ocorrências num processo de Poisson; sem memória.

Distribuição F-Snedecor

Usada em inferência sobre razões de variâncias.

Distribuição hipergeométrica

Nº de sucessos em n extracções sem reposição.

Distribuição normal

Distribuição em forma de sino; $N(\mu, \sigma)$.

Distribuição qui-quadrado

Assimétrica positiva; usada em inferência sobre variâncias.

Distribuição t-Student

Simétrica; usada quando σ^2 é desconhecida; caudas mais pesadas.

Distribuição uniforme

Probabilidade proporcional ao comprimento do subintervalo.

Erro tipo I (α)

Rejeitar H_0 quando é verdadeira; nível de significância.

Erro tipo II (β)

Não rejeitar H_0 quando é falsa.

Esperança matemática ($E[X]$)

Valor médio de uma variável aleatória (μ).

Estatística de teste

Estimador cujo valor determina a decisão no teste de hipóteses.

Estimação pontual

Estimação de parâmetro por um único valor ($\bar{x}$, s^2 , $\hat{p}$).

Estimador / Estatística

Função de uma amostra aleatória (variável aleatória).

Frequência absoluta (F_i)

Número de vezes que cada categoria ocorre.

Frequência relativa (f_i)

Proporção de cada categoria no total (F_i/n).

Função de distribuição (F)

$P[X \leq x]$; probabilidade acumulada.

Função densidade de probabilidade (f)

Para contínuas; área = probabilidade.

Função massa de probabilidade (f)

Para discretas; associa prob. a cada valor.

Hipótese alternativa (H_1)

Condiciona o tipo de teste; complementa H_0 .

Hipótese nula (H_0)

Contém a condição de igualdade; testada diretamente.

i.i.d.

Independentes e identicamente distribuídas (amostras).

Inferência estatística

Generalização dos resultados da amostra à população.

Intervalo de confiança

Intervalo que contém θ com probabilidade $1-\alpha$.

Intervalo inter-quartis (IQ)

$Q_3 - Q_1$; dispersão dos 50% centrais.

Kolmogorov-Smirnov

Teste de aderência à normalidade (Lilliefors).

Mediana (Me)

Valor que divide a amostra ordenada ao meio; Q_2 .

Método dos mínimos quadrados

Minimiza SQE para estimar a reta de regressão.

Moda (Mo)

Valor/categoria com maior frequência.

Nível de confiança (1- α)

Probabilidade do IC conter o verdadeiro parâmetro.

Nível de significância (α)

Prob. de rejeitar H_0 quando é verdadeira; comum: 0,05 e 0,01.

Normal reduzida / padrão

$Z \sim N(0,1)$; $\mu=0$, $\sigma=1$.

Outlier

Observação muito afastada das restantes; influencia média e desvio padrão.

p-value

Menor α a partir do qual se rejeita H_0 .

Partição

Acontecimentos mutuamente exclusivos que cobrem S.

Poisson

Nº de ocorrências num intervalo; λ = número médio de ocorrências.

Potência do teste (1- β)

Prob. de rejeitar H_0 quando é falsa.

Probabilidade condicionada

$P[A|B] = P[A \cap B] / P[B]$.

Processo de Poisson

Ocorrências independentes, prob. proporcional ao intervalo.

Proporção amostral ($\hat{p}$)

Estima a proporção populacional p .

Quantil de ordem p (Q_p)

Valor abaixo do qual está a proporção p das observações.

Quartil

Q_1 , Q_2 =Mediana, Q_3 ; dividem em 4 partes iguais.

Recta de regressão

$\hat{y} = a + bx$; ajustada pelo método dos mínimos quadrados.

Região crítica

Conjunto de valores que levam à rejeição de H_0 .

Resíduo

$e_i = y_i - \hat{y}_i$; erro de estimação na regressão.

Shapiro-Wilk

Teste de aderência à normalidade.

SQE / SQR / SQT

Soma de quadrados dos erros / regressão / total.

Teorema de Bayes

Calcula $P[A_i|B]$ a partir de $P[B|A_i]$ e probabilidades a priori.

Teorema do Limite Central

Soma de n i.i.d. $\rightarrow$ normal para $n > 30$.

Teorema da Probabilidade Total

$P[B] = \sum P[A_i] \cdot P[B|A_i]$ com $\{A_i\}$ partição.

Variância (s^2 / σ^2)

Média dos quadrados dos desvios em relação à média.

Variável aleatória

Função do espaço amostral na reta real.

Variável fulcral

Estatística amostral com distribuição conhecida; base do IC.