

1. Testes de hipóteses

Contexto geral e problema central: Metodologia estatística para tomar decisões acerca dos parâmetros da população com base em amostras. Inclui testes paramétricos (para distribuições conhecidas) e não paramétricos (para distribuições desconhecidas).

Testes de hipóteses paramétricos

Principais elementos:

- **Hipótese nula (H_0):** Afirmação sobre o parâmetro populacional (ex: $\mu = 10$, $\mu \leq 10$, $\mu \geq 10$)
- **Hipótese alternativa (H_1):** Afirmação que será verdadeira se H_0 for falsa (ex: $\mu \neq 10$, $\mu > 10$, $\mu < 10$)
- **Estatística de teste:** Estimador do parâmetro
- **Regra de decisão:** Baseada em regiões críticas/aceitação

Tipos de testes:

Tipo	H_0	H_1	Região crítica
Bilateral	$\theta = \theta_0$	$\theta \neq \theta_0$	$\alpha/2$ em cada cauda
Unilateral à direita	$\theta \leq \theta_0$	$\theta > \theta_0$	α na cauda direita
Unilateral à esquerda	$\theta \geq \theta_0$	$\theta < \theta_0$	α na cauda esquerda

Valor p (p-value): Menor nível de significância (α) a partir do qual se rejeita H_0 . Se $\alpha \geq p\text{-value}$, rejeita-se H_0 .

Erros de inferência

Decisão	H_0 verdadeira	H_0 falsa
Rejeitar H_0	Erro Tipo I (α)	Decisão correta
Não rejeitar H_0	Decisão correta	Erro Tipo II (β)

Relação entre erros:

- Para α fixo, aumentar n reduz β
- Para n fixo, diminuir α aumenta β
- Para reduzir ambos, aumentar n

Testes de hipóteses não paramétricos

Teste de Lilliefors-Kolmogorov-Smirnov:

- Testa se amostra é normal
- **Estatística:** $D = \max\{D^+, D^-\}$
- **Hipóteses:** $H_0: S_n(x) = F(x)$ vs $H_1: S_n(x) \neq F(x)$

- **Regra:** Rejeitar H_0 se $D \geq D_{\text{crítico}}$ ou $\alpha \geq p\text{-value}$

Teste de Shapiro-Wilk:

- Testa normalidade
- **Estatística:** $W = (\sum a_i x_{(i)})^2 / \sum (x_i - \bar{x})^2$
- **Regra:** Rejeitar H_0 se $W \leq W_{\text{crítico}}$ ou $\alpha \geq p\text{-value}$

p-value e valor crítico

- **p-value:** Menor α que leva à rejeição de H_0
- **Valor crítico:** Valor tabelado da distribuição que separa região crítica de aceitação

Conclusões práticas:

- Testes paramétricos exigem pressupostos (normalidade, variância conhecida)
- Testes não paramétricos são mais robustos mas menos poderosos
- Escolha do teste depende da distribuição dos dados e do objetivo

Termos-chave: Hipótese nula, hipótese alternativa, região crítica, p-value, erro Tipo I/II, teste de Lilliefors, teste de Shapiro-Wilk, normalidade

2. Correlação e regressão linear

Contexto geral e problema central: Estabelecer e quantificar relações matemáticas entre variáveis para prever comportamentos.

Regressão linear simples

Modelo: $Y = \beta_0 + \beta_1 x + E$

- Y: Variável dependente
- x: Variável independente
- β_0 : Interseção
- β_1 : Declive
- E: Erro/resíduo

Método dos mínimos quadrados: Minimiza $\sum (y_i - \hat{y}_i)^2$ para estimar β_0 e β_1 :

- $b = s_{xy} / s_{xx}$
- $a = \bar{y} - b \bar{x}$

Coeficiente de determinação (R^2): $R^2 = SQR / SQT = 1 - SQE / SQT = (s_{xy})^2 / (s_{xx} s_{yy})$

- $0 \leq R^2 \leq 1$
- Indica % da variabilidade de Y explicada por x

Covariância e correlação

Covariância (s_{xy}):

- Medida de associação linear
- $s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) / (n-1)$
- Interpretação:
 - $s_{xy} > 0$: relação linear positiva
 - $s_{xy} < 0$: relação linear negativa
 - $s_{xy} = 0$: não há relação linear

Coeficiente de correlação linear (r): $r = s_{xy} / (s_x s_y)$

- $-1 \leq r \leq 1$
 - $r = \pm 1$: correlação perfeita
 - $r = 0$: não há correlação linear
 - $|r| \geq 0.7$: correlação aceitável em engenharia
-

Inferência estatística

Pressupostos do modelo:

1. $E_i \sim N(0, \sigma^2)$
2. E_i são independentes
3. Variância constante

Análise de resíduos:

- Gráficos de resíduos vs valores ajustados
- Normalidade dos resíduos
- Ausência de padrões sistemáticos

Intervalos de confiança e testes:

- IC para β_0 , β_1 e previsões
 - Testes para significância dos coeficientes
 - Testes para qualidade do ajuste
-

Passos para construção de modelos

1. Identificar variáveis
 2. Coletar dados
 3. Criar diagrama de dispersão
 4. Calcular correlação
 5. Estimar reta de regressão
 6. Analisar resíduos
 7. Validar pressupostos
 8. Interpretar resultados
-

Termos-chave: Regressão linear, coeficiente de determinação, covariância, correlação, mínimos quadrados, resíduos, pressupostos

3. Variáveis aleatórias e modelos teóricos unidimensionais discretos

Contexto geral e problema central: Modelar fenômenos aleatórios discretos com distribuições teóricas.

Noção de variável aleatória

Definição: Função $X: S \rightarrow \mathbb{R}$ que associa resultados de uma experiência aleatória a valores numéricos.

Classificação:

- **Discreta:** Valores finitos ou infinitos numeráveis
 - **Contínua:** Valores em intervalos reais
-

Função massa de probabilidade ($f(x)$)

Definição: $f(x) = P(X = x_i)$ para $x = x_i$, 0 caso contrário

Propriedades:

- $f(x) \geq 0$
 - $\sum f(x_i) = 1$
-

Função de distribuição ($F(x)$)

$F(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i)$

Parâmetros

Parâmetro	Fórmula	Interpretação
Média	$E[X] = \sum x_i f(x_i)$	Valor esperado
Variância	$\text{Var}[X] = E[(X - \mu)^2] = \sum (x_i - \mu)^2 f(x_i)$	Dispersão
Desvio padrão	$\sigma = \sqrt{\text{Var}[X]}$	Variabilidade
Coeficiente de variação	$C_v = \sigma / \mu$	μ

Modelos discretos

Modelo	Parâmetros	Função massa	Média	Variância
Bernoulli	p	$f(x) = p^x(1-p)^{1-x}$	p	$p(1-p)$
Binomial	n, p	$f(x) = C_{nx} p^x(1-p)^{n-x}$	np	$np(1-p)$
Hipergeométrica	N, n, K	$f(x) = [C_{Kx} C_{n-Kx-x}] / C_{nn}$	np	$np(1-p)(N-n)/(N-1)$
Poisson	λ	$f(x) = \lambda^x e^{-\lambda} / x!$	λ	λ

Termos-chave: Variável discreta, função massa, Bernoulli, binomial, hipergeométrica, Poisson

4. Estimação por intervalos de confiança

Contexto geral e problema central: Fornecer intervalos que contenham o verdadeiro valor do parâmetro populacional com uma dada probabilidade.

Conceitos fundamentais

População vs Amostra:

- População: Parâmetros desconhecidos (μ, σ^2, p)
- Amostra: Estatísticas ($\bar{x}, s^2, \hat{p}$)

Estimação pontual:

- Estimador: Estatística amostral
- Estimativa: Valor numérico do estimador

Distribuições amostrais

Parâmetro	Estimador	Distribuição	Pressupostos
μ	$\bar{X}$	Normal reduzida	$n \geq 30$ ou σ conhecido
μ	$\bar{X}$	t-Student	σ desconhecido, $n < 30$
σ^2	S^2	Qui-quadrado	Normalidade

Construção de IC

Passos:

1. Identificar parâmetro
2. Escolher nível de confiança ($1-\alpha$)
3. Selecionar variável fulcral
4. Calcular valor crítico
5. Construir intervalo: IC = [estimador - E; estimador + E] onde $E = z_{1-\alpha/2} \times \sigma/\sqrt{n}$ (ou $t_{1-\alpha/2} \times s/\sqrt{n}$)

Nível de confiança comum:

- 90%: $z = 1.645$
- 95%: $z = 1.96$
- 99%: $z = 2.576$

Margem de erro

$$E = \text{amplitude}/2 = z_{1-\alpha/2} \times \sigma/\sqrt{n}$$

Termos-chave: Intervalo de confiança, nível de confiança, variável fulcral, margem de erro

5. Teoria das probabilidades

Contexto geral e problema central: Medir a incerteza associada a acontecimentos aleatórios.

Conceitos fundamentais

Experiência aleatória: Procedimento com resultados não previsíveis mas conhecidos **Espaço de resultados**

(S): Conjunto de todos os resultados possíveis **Acontecimentos:** Subconjuntos de S

Operações com acontecimentos:

Operação	Notação	Definição
Reunião	$A \cup B$	A ou B ocorre
Interseção	$A \cap B$	A e B ocorrem
Complementar	$\bar{A}$	A não ocorre
Diferença	$A \setminus B$	A ocorre sem B

Probabilidade**Definições:**

- **Clássica:** $P(A) = N_A/N$ (resultados equiprováveis)
- **Frequencista:** $P(A) = \lim N_A/N$
- **Subjetiva:** Baseada em crenças/evidências

Axiomas:

1. $P(A) \geq 0$
2. $P(S) = 1$
3. $A_i \cap A_j = \emptyset \Rightarrow P(\cup A_i) = \sum P(A_i)$

Probabilidade condicionada

$$P(A|B) = P(A \cap B) / P(B)$$

Teoremas

Teorema	Fórmula
Probabilidade total	$P(B) = \sum P(A_i)P(B A_i)$
Bayes	$P(A_j B) = \frac{P(A_j)P(B A_j)}{\sum P(A_i)P(B A_i)}$

Independência

$$A \text{ e } B \text{ independentes} \Leftrightarrow P(A \cap B) = P(A)P(B)$$

Termos-chave: Acontecimentos, probabilidade, condicionada, Bayes, independência

6. Estatística descritiva e análise exploratória de dados

Contexto geral e problema central: Resumir e interpretar grandes conjuntos de dados de forma eficiente.

Tipos de variáveis

Tipo	Características	Exemplos
Qualitativa	Não mensurável	Cor, gênero
Quantitativa	Mensurável	Altura, peso

Organização de dados

Variáveis qualitativas:

- Tabela de frequências
- Gráficos: sectograma, barras

Variáveis quantitativas:

- Dados não agrupados
 - Dados agrupados (classes)
-

Medidas de localização

Medida	Fórmula	Interpretação
Moda	Valor mais frequente	Tendência central
Mediana	$Q_{0.5} = x_{(\lfloor n/2 \rfloor)} + kx_{(\lfloor n/2 \rfloor + 1)}$	Valor central
Média	$\bar{x} = \sum x_i/n$	Centro de gravidade

Medidas de dispersão

Medida	Fórmula	Interpretação
Amplitude	$R = \max - \min$	Variação total
Intervalo interquartis	$IQ = Q_3 - Q_1$	Variação central
Variância	$s^2 = \sum (x_i - \bar{x})^2 / (n-1)$	Dispersão quadrática
Desvio padrão	$s = \sqrt{s^2}$	Dispersão absoluta
Coeficiente variação	$C_v = s / \bar{x}$	

Outliers e boxplot

Identificação de outliers:

- Moderados: $Q_1 - 1.5IQ < x < Q_1 - 3IQ$ ou $Q_3 + 1.5IQ < x < Q_3 + 3IQ$
- Extremos: $x < Q_1 - 3IQ$ ou $x > Q_3 + 3IQ$

Termos-chave: Medidas de tendência central, dispersão, outliers, boxplot

7. Variáveis aleatórias e modelos teóricos unidimensionais contínuos

Contexto geral e problema central: Modelar fenômenos contínuos com distribuições teóricas.

Função densidade ($f(x)$)

Definição: $f(x)dx = P(x \leq X \leq x+dx)$

Propriedades:

- $f(x) \geq 0$
- $\int_{-\infty}^{+\infty} f(x)dx = 1$

Função de distribuição ($F(x)$)

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

Parâmetros

Parâmetro	Fórmula	Interpretação
Média	$E[X] = \int x f(x)dx$	Valor esperado
Variância	$Var[X] = \int (x-\mu)^2 f(x)dx$	Dispersão
Desvio padrão	$\sigma = \sqrt{Var[X]}$	Variabilidade

Modelos contínuos

Modelo	Função densidade	Média	Variância
Exponencial	$f(x) = \lambda e^{-\lambda x}$	$1/\lambda$	$1/\lambda^2$
Uniforme (a,b)	$f(x) = 1/(b-a)$	$(a+b)/2$	$(b-a)^2/12$
Normal (μ, σ)	$f(x) = e^{-(x-\mu)^2/2\sigma^2} / (\sigma\sqrt{2\pi})$	μ	σ^2

Distribuição Normal

Propriedades:

- Simétrica em torno de μ
- 68% dos dados entre $\mu \pm \sigma$
- 95% entre $\mu \pm 2\sigma$
- 99.7% entre $\mu \pm 3\sigma$

Padronização: $Z = (X-\mu)/\sigma \sim N(0,1)$

Teorema do limite central: Para n grande ($n > 30$), $\bar{X} \sim N(\mu, \sigma/\sqrt{n})$

Aproximações

- Binomial(N, p) $\sim$ Normal($Np, \sqrt{Np(1-p)}$) se $N > 20$ e $Np \geq 5$
- Poisson(λ) $\sim$ Normal($\lambda, \sqrt{\lambda}$) se $\lambda > 20$

Termos-chave: Função densidade, distribuição normal, padronização, teorema limite central