

Probabilidades e Estatística — Resumo de Matéria

LEIC / ISEL — Departamento de Matemática

Documento gerado a partir da análise cruzada de 8 provas (1.º e 2.º testes + exames de 1.ª e 2.ª época, anos letivos 2021/22, 2022/23 e 2024/25).

Índice

1. Estatística Descritiva
2. Probabilidade
3. Variáveis Aleatórias Discretas
4. Variáveis Aleatórias Contínuas
5. Teorema do Limite Central
6. Estimação Pontual
7. Intervalos de Confiança
8. Testes de Hipóteses
9. Regressão Linear Simples
10. Termos-Chave

1. Estatística Descritiva

A estatística descritiva serve para **resumir e caracterizar** um conjunto de dados (amostra), sem fazer generalizações para a população. É o ponto de partida de qualquer análise.

1.1 Medidas de Tendência Central

Média Amostral

A média aritmética de uma amostra de dimensão n :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Mediana

Valor que divide a amostra ordenada em duas metades iguais.

- Se n é ímpar: elemento central.
- Se n é par: média dos dois elementos centrais.

Moda

Valor (ou classe) que ocorre com maior frequência. Para dados agrupados em classes, **a classe modal** é a de maior frequência absoluta.

Relação entre Média, Mediana e Simetria

A comparação entre média e mediana permite inferir a simetria da distribuição:

- **Distribuição simétrica:** média $\approx$ mediana.
- **Assimetria positiva (à direita):** média $>$ mediana — os valores elevados "puxam" a média.
- **Assimetria negativa (à esquerda):** média $<$ mediana — os valores baixos "puxam" a média.

1.2 Medidas de Dispersão

Variância Amostral

Mede o afastamento médio quadrático dos valores em relação à média:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Forma computacionalmente equivalente:

$$s^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

Desvio Padrão Amostral

$$s = \sqrt{s^2}$$

Coeficiente de Variação (CV)

Medida de dispersão **relativa**, útil para comparar variabilidade entre amostras com diferentes unidades ou magnitudes:

$$CV = \frac{s}{\bar{x}} \times 100\%$$

Atenção: quando se compara a variabilidade de duas amostras com médias muito diferentes, deve usar-se o CV e não o desvio padrão diretamente.

1.3 Quartis e Diagrama de Caixa

Os **quartis** dividem os dados ordenados em quatro partes iguais:

- Q_1 — 1.º quartil (25% dos dados ficam abaixo)
- Q_2 — mediana (50%)
- Q_3 — 3.º quartil (75%)

Amplitude Interquartil (IQR): $IQR = Q_3 - Q_1$

Deteção de Outliers (Regra das Cercas)

Um valor x é **outlier** se: $x < Q_1 - 1,5 \times IQR$ ou $x > Q_3 + 1,5 \times IQR$

1.4 Dados Agrupados em Classes

Para calcular mediana e quartis em dados agrupados, utiliza-se interpolação linear dentro da classe que contém o valor procurado. A mediana pertence à classe cuja frequência relativa acumulada ultrapassa 0,5 pela primeira vez.

2. Probabilidade

2.1 Conceitos Fundamentais

- **Experiência aleatória:** experiência cujo resultado não é previsível com certeza.
- **Espaço amostral (Ω):** conjunto de todos os resultados possíveis.
- **Evento:** subconjunto do espaço amostral.
- **Probabilidade de um evento A :** $P(A) \in [0, 1]$, com $P(\Omega) = 1$.

2.2 Probabilidade Condicional

A probabilidade de A ocorrer **dado que** B já ocorreu:

$$\boxed{P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0}$$

2.3 Independência de Eventos

Dois eventos A e B são **independentes** se e só se:

$$P(A \cap B) = P(A) \times P(B)$$

Equivalentemente, $P(A \mid B) = P(A)$.

2.4 Teorema da Probabilidade Total

Seja $\{B_1, B_2, \dots, B_k\}$ uma **partição** do espaço amostral (eventos mutuamente exclusivos e coletivamente exaustivos). Para qualquer evento A :

$$\boxed{P(A) = \sum_{i=1}^k P(A \mid B_i) \times P(B_i)}$$

Aplicação típica: saber a probabilidade total de um evento quando se conhecem as probabilidades condicionais em cada "ramo" de uma partição (e.g., quotas de mercado de empresas, proporções de produção).

2.5 Teorema de Bayes

Permite "inverter" a probabilidade condicional — dado que o evento A ocorreu, qual a probabilidade de ter "vindo" do ramo B_j ?

$$\boxed{P(B_j \mid A) = \frac{P(A \mid B_j) \times P(B_j)}{\sum_{i=1}^k P(A \mid B_i) \times P(B_i)}}$$

O denominador é precisamente $P(A)$ pelo Teorema da Probabilidade Total.

3. Variáveis Aleatórias Discretas

Uma **variável aleatória discreta (v.a.d.)** X toma um conjunto finito ou infinito numerável de valores, cada um com uma probabilidade associada.

3.1 Função de Probabilidade

$$f(x) = P(X = x), \quad \text{para cada valor possível } x$$

Condições obrigatórias:

1. $f(x) \geq 0$ para todo o x
2. $\sum_{\text{todos os } x} f(x) = 1$

3.2 Valor Esperado (Esperança Matemática)

$$\mu = E[X] = \sum_{x} x \cdot f(x)$$

Para funções de v.a.: $E[g(X)] = \sum_{x} g(x) \cdot f(x)$

Propriedades lineares:

- $E[aX + b] = aE[X] + b$
- $E[X + Y] = E[X] + E[Y]$ (sempre válido)

3.3 Variância e Desvio Padrão

$$\sigma^2 = \text{Var}(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2$$

$$\sigma = \sqrt{\text{Var}(X)}$$

Propriedades:

- $\text{Var}(aX + b) = a^2 \cdot \text{Var}(X)$

3.4 Distribuição de Bernoulli

Experiência com dois resultados: sucesso (probabilidade p) ou insucesso (probabilidade $1-p$). Representa um único ensaio.

$$X \sim \text{Bernoulli}(p): \quad f(0) = 1-p, \quad f(1) = p \quad E[X] = p, \quad \text{Var}(X) = p(1-p)$$

3.5 Distribuição Binomial

Modela o **número de sucessos** em n ensaios de Bernoulli **independentes**, com a mesma probabilidade de sucesso p .

$$X \sim \text{Bin}(n, p): \quad f(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n$$

$$E[X] = np, \quad \text{Var}(X) = np(1-p)$$

Quando usar: número de pacotes sem defeitos, número de bits defeituosos em transmissão, número de testes bem-sucedidos.

3.6 Distribuição de Poisson

Modela o **número de ocorrências** de um evento num intervalo de tempo (ou espaço) fixo, quando as ocorrências são independentes e a taxa média é constante.

$$X \sim \text{Poisson}(\lambda): \quad f(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

$$E[X] = \text{Var}(X) = \lambda$$

Reescalonamento do parâmetro: se $X \sim \text{Poisson}(\lambda)$ para um intervalo de referência, então para um intervalo de comprimento t : $X_t \sim \text{Poisson}(\lambda \cdot t)$

Exemplo: se a taxa é 9 acessos/minuto ($\lambda = 9$), então em 25 segundos ($t = 25/60$) o parâmetro passa a $\lambda' = 9 \cdot \frac{25}{60} = 3.75$.

Quando usar: número de acessos a um servidor/website por período, número de avarias, número de incidentes informáticos por mês.

3.7 Distribuição Hipergeométrica

Modela o número de sucessos em n extrações **sem reposição** de uma população finita de N elementos, dos quais M são de interesse.

$$X \sim \text{Hiper}(N, M, n): \quad f(x) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}$$

$$E[X] = n \frac{M}{N}, \quad \text{Var}(X) = n \frac{M}{N} \frac{N-M}{N} \frac{N-n}{N-1}$$

Quando usar: extração de peças defeituosas de um lote sem reposição.

4. Variáveis Aleatórias Contínuas

Uma **variável aleatória contínua (v.a.c.)** pode tomar qualquer valor num intervalo real. A probabilidade de tomar um valor **exato** é zero — só faz sentido calcular probabilidades em intervalos.

4.1 Função Densidade de Probabilidade (f.d.p.)

Uma função $f(x)$ é f.d.p. se e só se:

- $f(x) \geq 0$ para todo o x
- $\int_{-\infty}^{+\infty} f(x) dx = 1$

A probabilidade num intervalo é: $P(a < X < b) = \int_a^b f(x) dx$

4.2 Função de Distribuição Acumulada (F.D.A.)

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

Propriedades:

- F é não-decrescente
- $F(-\infty) = 0$, $F(+\infty) = 1$
- $P(a < X < b) = F(b) - F(a)$
- $f(x) = F'(x)$ (quando a derivada existe)

4.3 Valor Esperado e Variância

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \int_{-\infty}^{+\infty} x^2 f(x) dx - \mu^2$$

4.4 Distribuição Uniforme Contínua

Modela uma v.a. que toma qualquer valor em $[a, b]$ com igual probabilidade.

$$X \sim U(a, b): \quad f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

$$E[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

Percentil p : o valor x_p tal que $P(X \leq x_p) = p$ é $x_p = a + p(b-a)$.

Quando usar: tempo até à primeira falha uniformemente distribuído num intervalo, diâmetros de cabos elétricos dentro de uma gama.

4.5 Distribuição Exponencial

Modela o **tempo de espera** entre eventos de um processo de Poisson.

$$X \sim \text{Exp}(\lambda): \quad f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}, \quad \sigma = \frac{1}{\lambda}$$

$$\text{A F.D.A. tem forma fechada: } F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

$$\text{Portanto: } P(X > t) = e^{-\lambda t}$$

Relação com Poisson: se o número de ocorrências por unidade de tempo segue $\text{Poisson}(\lambda)$, o tempo entre ocorrências consecutivas segue $\text{Exp}(\lambda)$.

$$\text{Mediana: } x_{0,5} = \frac{\ln 2}{\lambda} \approx \frac{0,6931}{\lambda}$$

$$\text{Propriedade da falta de memória: } P(X > s + t \mid X > s) = P(X > t)$$

Quando usar: tempo entre dois acessos consecutivos a um servidor, tempo de reparação de avarias, tempo de resposta de um servidor.

4.6 Distribuição Normal

A mais importante distribuição contínua em estatística.

$$X \sim N(\mu, \sigma^2): \quad f(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2}, \quad x \in \mathbb{R}$$

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

Padronização (Normal Reduzida): se $X \sim N(\mu, \sigma^2)$, então: $Z = \frac{X - \mu}{\sigma} \sim N(0,1)$

As probabilidades obtêm-se a partir de tabelas da normal padrão $\Phi(z) = P(Z \leq z)$.

Propriedades importantes:

- A distribuição é simétrica em torno de μ
- $P(Z \leq z) = 1 - P(Z \leq -z)$, ou seja, $\Phi(-z) = 1 - \Phi(z)$
- **Regra empírica:** $P(\mu - \sigma < X < \mu + \sigma) \approx 68\%$; $P(\mu - 2\sigma < X < \mu + 2\sigma) \approx 95\%$

Percentil: dado p , o valor x_p tal que $P(X \leq x_p) = p$ é: $x_p = \mu + z_p \cdot \sigma$ onde z_p é o quantil da normal padrão correspondente ao nível p .

Soma de normais independentes: se $X_1 \sim N(\mu_1, \sigma_1^2)$ e $X_2 \sim N(\mu_2, \sigma_2^2)$ independentes: $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

5. Teorema do Limite Central

O **Teorema do Limite Central (TLC)** é um dos resultados mais fundamentais de toda a probabilidade e estatística inferencial.

5.1 Enunciado

Seja $X_1, X_2, \dots, X_n$ uma amostra aleatória de v.a. **independentes e identicamente distribuídas (i.i.d.)** com média μ e variância σ^2 finitas (distribuição qualquer). Então, para n suficientemente grande:

$$\boxed{\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \overset{\text{aprox.}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)}$$

Equivalentemente, a **soma** $S_n = X_1 + \dots + X_n$ satisfaz: $S_n \overset{\text{aprox.}}{\sim} N(n\mu, n\sigma^2)$

A padronização correspondente é: $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{S_n - n\mu}{\sigma\sqrt{n}} \overset{\text{aprox.}}{\sim} N(0, 1)$

Como **regra prática**, considera-se $n \geq 30$ suficientemente grande para aplicar o TLC. Se a população original já for normal, o resultado é exato para qualquer n .

5.2 Aplicação Típica

O TLC permite calcular probabilidades sobre a **média** ou a **soma** de amostras de grande dimensão, mesmo quando a distribuição original não é normal (e.g., exponencial, Poisson, uniforme).

Distribuição amostral de $\bar{X}$: $E[\bar{X}] = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$

O fator $\sigma/\sqrt{n}$ chama-se **erro padrão da média**.

6. Estimação Pontual

A estimação pontual consiste em usar um valor único calculado a partir da amostra — um **estimador** — para aproximar um parâmetro populacional desconhecido.

6.1 Estimadores Clássicos

Parâmetro	Estimador Pontual
Média μ	$\hat{\mu} = \bar{X} = \frac{1}{n} \sum x_i$

Parâmetro	Estimador Pontual
Variância σ^2	$\hat{\sigma}^2 = s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$
Desvio padrão σ	$\hat{\sigma} = s = \sqrt{s^2}$
Proporção p	$\hat{p} = \frac{\text{text{n.º de sucessos}}}{n}$

6.2 Propriedades Desejáveis de um Estimador

- **Não enviesado (sem viés):** $E[\hat{\theta}] = \theta$ — em média, o estimador acerta no parâmetro.
- **Consistente:** o estimador converge para o parâmetro verdadeiro à medida que $n \rightarrow \infty$.
- **Eficiente:** entre estimadores não enviesados, tem menor variância.

Nota: s^2 com divisão por $n-1$ é **não enviesado** para σ^2 . Se dividíssemos por n , seria enviesado.

7. Intervalos de Confiança

Um **intervalo de confiança (IC)** a $(1-\alpha) \times 100\%$ é um intervalo aleatório que contém o verdadeiro valor do parâmetro com probabilidade $1-\alpha$.

Interpretação correta: se construirmos muitos intervalos de confiança de 95%, em 95% dos casos o verdadeiro parâmetro estará dentro do intervalo. Não significa que há 95% de probabilidade de o parâmetro estar neste intervalo específico.

Amplitude do IC: aumenta com o nível de confiança e diminui com o tamanho da amostra n .

7.1 IC para a Média μ com σ Conhecido

Distribuição amostral: $\bar{X} \sim N(\mu, \sigma^2/n)$ (exata se população normal; aproximada pelo TLC).

$$\boxed{IC_{1-\alpha}(\mu) = \left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} ; \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]}$$

Onde $z_{1-\alpha/2}$ é o quantil da Normal padrão. Valores mais usados:

- $\alpha = 0.05$: $z_{0.975} = 1.96$
- $\alpha = 0.10$: $z_{0.95} = 1.645$
- $\alpha = 0.01$: $z_{0.995} = 2.576$

7.2 IC para a Média μ com σ Desconhecido

Quando σ é desconhecido, estima-se por s e usa-se a distribuição **t-Student** com $n-1$ graus de liberdade.

$$\boxed{IC_{1-\alpha}(\mu) = \left[\bar{x} - t_{n-1; 1-\alpha/2} \frac{s}{\sqrt{n}} ; \bar{x} + t_{n-1; 1-\alpha/2} \frac{s}{\sqrt{n}} \right]}$$

A distribuição t-Student é mais "achatada" que a normal padrão, produzindo intervalos mais largos — o que reflete a incerteza adicional por não conhecer σ . Para n grande ($n > 30$), aproxima-

se da normal.

7.3 IC para a Variância σ^2

Usa-se a distribuição **Qui-Quadrado** (χ^2) com $n-1$ graus de liberdade.

A estatística pivô é: $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{n-1}$

$$\boxed{IC_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)s^2}{\chi^2_{n-1; 1-\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{n-1; \alpha/2}} \right]}$$

Atenção: ao contrário da normal, a distribuição qui-quadrado **não é simétrica** — os dois quantis são diferentes e devem ser lidos com cuidado da tabela.

7.4 IC para a Diferença de Médias ($\mu_1 - \mu_2$)

Para duas amostras independentes com σ_1 e σ_2 conhecidos:

$$\boxed{IC_{1-\alpha}(\mu_1 - \mu_2) = \left[\bar{x}_1 - \bar{x}_2 \pm z_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]}$$

Quando as variâncias são desconhecidas e as amostras são grandes, substitui-se σ_i por s_i e usa-se a normal padrão (TLC).

8. Testes de Hipóteses

Um **teste de hipóteses** é um procedimento estatístico para tomar uma decisão sobre um parâmetro populacional, com base em dados amostrais e controlando a probabilidade de erro.

8.1 Estrutura Geral

Hipóteses:

- H_0 — **hipótese nula**: afirmação sobre o parâmetro que se testa (geralmente contém o sinal $=$, $\leq$ ou $\geq$).
- H_1 — **hipótese alternativa**: o que se quer demonstrar (contém $\neq$, $>$ ou $<$).

Tipos de teste:

- Bilateral**: $H_1: \theta \neq \theta_0$ — rejeita em ambas as caudas.
- Unilateral à direita**: $H_1: \theta > \theta_0$ — rejeita apenas na cauda direita.
- Unilateral à esquerda**: $H_1: \theta < \theta_0$ — rejeita apenas na cauda esquerda.

Erros possíveis:

	H_0 verdadeira	H_0 falsa
Não rejeitar H_0	Decisão correta	Erro tipo II (β)
Rejeitar H_0	Erro tipo I (α)	Decisão correta

- **Nível de significância α :** probabilidade máxima tolerada de cometer o Erro tipo I (e.g., $\alpha = 0{,}05$ ou $\alpha = 0{,}01$).

8.2 Estatística de Teste e Regiões

O procedimento consiste em:

1. Formular H_0 e H_1 .
2. Calcular a **estatística de teste** (valor numérico calculado a partir da amostra).
3. Definir a **Região Crítica (RC)** — conjunto de valores da estatística que levam à rejeição de H_0 .
4. **Decisão:** se o valor observado pertence à RC, rejeita-se H_0 ; caso contrário, não se rejeita.

8.3 p-value

O **p-value** é a probabilidade de obter um resultado tão ou mais extremo que o observado, assumindo que H_0 é verdadeira.

$\text{Se } p\text{-value} \leq \alpha \rightarrow \text{Rejeitar } H_0$
 $\text{Se } p\text{-value} > \alpha \rightarrow \text{Não rejeitar } H_0$

O p-value **não** é a probabilidade de H_0 ser verdadeira. É uma medida de compatibilidade entre os dados e H_0 .

8.4 Teste para a Média μ com σ Conhecido (Teste Z)

$H_0: \mu = \mu_0$ ou $\mu \leq \mu_0$ ou $\mu \geq \mu_0$

Estatística de teste: $Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1)$ sob H_0

Regiões críticas para α :

- Bilateral ($H_1: \mu \neq \mu_0$): $RC = \{|Z_0| > z_{1-\alpha/2}\}$
- Unilateral direita ($H_1: \mu > \mu_0$): $RC = \{Z_0 > z_{1-\alpha}\}$
- Unilateral esquerda ($H_1: \mu < \mu_0$): $RC = \{Z_0 < -z_{1-\alpha}\}$

8.5 Teste para a Média μ com σ Desconhecido (Teste t)

Estatística de teste: $T_0 = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$ sob H_0

Regiões críticas análogas ao teste Z, mas usando quantis da t-Student com $n-1$ graus de liberdade.

8.6 Teste para a Variância σ^2 (Teste Qui-Quadrado)

$H_0: \sigma^2 = \sigma_0^2$

Estatística de teste: $\chi^2_0 = \frac{(n-1)s^2}{\sigma_0^2} \sim \chi^2_{n-1}$ sob H_0

- Unilateral direita ($H_1: \sigma^2 > \sigma_0^2$): $RC = \{\chi^2_0 > \chi^2_{n-1; 1-\alpha}\}$
- Unilateral esquerda ($H_1: \sigma^2 < \sigma_0^2$): $RC = \{\chi^2_0 < \chi^2_{n-1; \alpha}\}$
- Bilateral: divide-se α em ambas as caudas.

8.7 Teste para a Proporção p (Teste Z)

$$H_0: p = p_0 \quad \text{(ou)} \quad p \leq p_0 \quad \text{ou} \quad p \geq p_0$$

Estatística de teste (aproximação normal para n grande):
$$Z_0 = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \approx N(0,1) \quad \text{sob } H_0$$

8.8 Teste para a Diferença de Médias

Para $X_1 \sim N(\mu_1, \sigma_1^2)$ e $X_2 \sim N(\mu_2, \sigma_2^2)$ independentes, com σ_1, σ_2 conhecidos:

$$Z_0 = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1) \quad \text{sob } H_0$$

Para grandes amostras com variâncias desconhecidas, substituem-se σ_i por s_i .

8.9 Teste de Ajustamento à Normalidade (Shapiro-Wilk)

O teste de Shapiro-Wilk avalia se uma amostra provém de uma população com distribuição normal.

H_0 : a população segue distribuição Normal
 H_1 : a população não segue distribuição Normal

Decisão com base no p-value:

- Se $p\text{-value} > \alpha$: **não se rejeita H_0** → não há evidência de afastamento da normalidade.
- Se $p\text{-value} \leq \alpha$: **rejeita-se H_0** → há evidência de que a distribuição não é normal.

Este teste é frequentemente usado como pré-requisito para validar a aplicação de testes paramétricos que assumem normalidade.

9. Regressão Linear Simples

A regressão linear simples modela a relação linear entre uma **variável resposta** (dependente) Y e uma **variável explicativa** (independente) x .

9.1 Modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

Onde:

- β_0 — **ordenada na origem** (valor de Y quando $x = 0$)
- β_1 — **declive/inclinação** (variação esperada em Y por cada unidade de aumento em x)
- ε_i — **erro aleatório**, assumido $\sim N(0, \sigma^2)$ i.i.d.

9.2 Estimação pelo Método dos Mínimos Quadrados

Os estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ *minimizam a soma dos quadrados dos resíduos*:
$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

As fórmulas dos estimadores são:

$$\boxed{\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}}$$

$$\boxed{\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}}$$

Onde: $S_{xx} = \sum_{i=1}^n x_i^2 - n\bar{x}^2$, $S_{yy} = \sum_{i=1}^n y_i^2 - n\bar{y}^2$, $S_{xy} = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$

9.3 Reta de Regressão Ajustada

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- **Resíduos (erros de estimação):** $e_i = y_i - \hat{y}_i$
- A reta passa sempre pelo ponto $(\bar{x}, \bar{y})$.

Interpretação dos coeficientes:

- $\hat{\beta}_1$: por cada unidade adicional em x , y varia em média $\hat{\beta}_1$ unidades.
- $\hat{\beta}_0$: valor estimado de y quando $x = 0$ (pode não ter interpretação física se $x=0$ está fora do domínio dos dados).

9.4 Coeficiente de Correlação Linear de Pearson

Mede a **força e direção** da associação linear entre x e y :

$$\boxed{r = \frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}}}$$

- $r \in [-1, 1]$
- $r > 0$: correlação positiva; $r < 0$: correlação negativa
- $|r|$ próximo de 1: associação linear forte; próximo de 0: associação linear fraca

9.5 Coeficiente de Determinação

Mede a **proporção da variabilidade total** de y explicada pela reta de regressão:

$$\boxed{R^2 = r^2 = \frac{S_{xy}^2}{S_{xx} \cdot S_{yy}} \in [0, 1]}$$

- $R^2 = 1$: ajuste perfeito (todos os pontos sobre a reta).
- $R^2 = 0$: o modelo não explica nada da variabilidade de y .
- **Interpretação:** "O modelo de regressão explica $R^2 \times 100\%$ da variabilidade total de y ."

9.6 Teste de Significância do Modelo de Regressão

Testa se o declive é significativamente diferente de zero, ou seja, se x tem poder explicativo sobre y :

$$H_0: \beta_1 = 0 \quad \text{vs} \quad H_1: \beta_1 \neq 0$$

A estatística de teste segue uma distribuição t-Student com $n-2$ graus de liberdade:

$$\boxed{T_0 = \frac{\hat{\beta}_1}{\hat{\sigma} / \sqrt{S_{xx}}} \sim t_{(n-2)} \quad \text{sob } H_0}$$

Onde $\hat{\sigma}^2 = \frac{\sum e_i^2}{n-2}$ é o estimador da variância dos erros.

- Se $|T_0| > t_{(n-2; 1-\alpha/2)}$: **rejeitar H_0** → o modelo é significativo.

- **Conclusão prática:** há evidência de relação linear significativa entre X e Y .

9.7 Normalidade dos Resíduos

Uma das hipóteses do modelo de regressão linear é que os erros $\epsilon_i \sim N(0, \sigma^2)$. Na prática, valida-se esta hipótese aplicando um **teste de ajustamento à normalidade** (e.g., Shapiro-Wilk) aos **resíduos** $e_i = y_i - \hat{y}_i$.

Termos-Chave

Termo	Descrição
Amostra	Subconjunto representativo de uma população
Assimetria	Grau de afastamento da simetria de uma distribuição
Coefficiente de Determinação (R^2)	Proporção da variância de Y explicada pelo modelo de regressão
Coefficiente de Correlação (r)	Medida da força e direção da relação linear entre duas v.a.
Coefficiente de Variação (CV)	Dispersão relativa: $s/\bar{x} \times 100\%$
Distribuição Binomial	N.º de sucessos em n ensaios independentes
Distribuição Exponencial	Tempo entre eventos de um processo de Poisson
Distribuição Normal	Distribuição contínua simétrica, fundamental em estatística
Distribuição de Poisson	N.º de ocorrências por unidade de tempo/espaco
Distribuição Qui-Quadrado (χ^2)	Usada em IC e testes para a variância
Distribuição t-Student	Usada em IC e testes para μ com σ desconhecido
Distribuição Uniforme	Todos os valores no intervalo $[a,b]$ igualmente prováveis
Erro Padrão	Desvio padrão do estimador: $\sigma/\sqrt{n}$ para $\bar{X}$
Erro tipo I	Rejeitar H_0 quando é verdadeira (probabilidade $= \alpha$)
Erro tipo II	Não rejeitar H_0 quando é falsa (probabilidade $= \beta$)
Estimador	Função da amostra usada para estimar um parâmetro
Função de Distribuição Acumulada (F.D.A.)	$F(x) = P(X \leq x)$
Função Densidade de Probabilidade (f.d.p.)	Define a probabilidade para v.a. contínuas
Graus de Liberdade	Parâmetro de distribuições t e χ^2 (tipicamente $n-1$ ou $n-2$)
Hipótese Nula (H_0)	Hipótese testada; contém o sinal de igualdade

Termo	Descrição
Hipótese Alternativa (H_1)	O que se pretende demonstrar
IQR	Amplitude interquartil: $Q_3 - Q_1$
Intervalo de Confiança	Intervalo aleatório que contém o parâmetro com probabilidade $1-\alpha$
Médiana	Valor central da amostra ordenada
Mínimos Quadrados	Método de estimação dos parâmetros de regressão
Nível de Confiança ($1-\alpha$)	Probabilidade de o IC conter o parâmetro verdadeiro
Nível de Significância (α)	Probabilidade máxima tolerada de Erro tipo I
Outlier	Observação anormalmente afastada das restantes
p-value	Probabilidade de resultado tão extremo ou mais, assumindo H_0
Probabilidade Condicional	$P(A$
Quartis (Q_1, Q_2, Q_3)	Dividem os dados em quatro partes iguais
Região Crítica	Conjunto de valores da estatística de teste que levam a rejeitar H_0
Resíduo	Diferença entre valor observado e valor ajustado: $e_i = y_i - \hat{y}_i$
Shapiro-Wilk	Teste de ajustamento à distribuição normal
Teorema de Bayes	Inversão da probabilidade condicional
Teorema do Limite Central (TLC)	$\bar{X}$ aproxima-se de normal para n grande
Teorema da Probabilidade Total	$P(A) = \sum P(A$
Valor Esperado (μ)	Média ponderada dos valores de uma v.a.
Variância (σ^2)	Medida de dispersão em torno da média
Variável Aleatória Contínua	Toma valores num intervalo; $P(X=x) = 0$
Variável Aleatória Discreta	Toma valores numeráveis com probabilidades positivas