

Fase 1: Análise e Mapeamento de Conteúdos

Após a leitura integral dos oito ficheiros (dois 1ºs Testes, dois 2ºs Testes, quatro Exames), identifiquei os seguintes temas centrais e a sua progressão lógica. A estrutura dos testes do ISEL (LEIC) segue um padrão claro: **1º Teste/Parte inicial do Exame** foca-se em **Probabilidades e Variáveis Aleatórias**, enquanto o **2º Teste/Parte final do Exame** foca-se em **Inferência Estatística e Regressão Linear**.

Progressão Lógica Inferida:

- Fundamentos de Probabilidade e Análise Exploratória de Dados:** Conceitos iniciais como Teorema de Bayes, probabilidade condicionada e medidas de localização/dispersão (média, mediana, outliers, assimetria).
- Modelos Probabilísticos Discretos:** Distribuições de Poisson, Binomial e Hipergeométrica. Relação entre Poisson e Exponencial (tempo entre eventos).
- Modelos Probabilísticos Contínuos:** Distribuições Uniforme, Exponencial e Normal (Gaussiana). Propriedades, cálculos de probabilidade, função densidade e função de distribuição. Teorema do Limite Central (TLC) aplicado a somas e médias.
- Estimação de Parâmetros (Inferência Estatística):** Estimativas pontuais (média, variância, proporção) e Intervalos de Confiança (para média com σ conhecido/desconhecido, para variância).
- Testes de Hipóteses:** Testes Paramétricos para uma ou duas populações (média, variância, proporção). Definição de H_0 vs H_1 , Região Crítica, Nível de Significância (α), e p -value. Testes de ajustamento à Normal (Shapiro-Wilk).
- Regressão Linear Simples:** Correlação, método dos mínimos quadrados, coeficientes da reta, coeficiente de determinação (R^2), e inferência sobre os parâmetros do modelo.

Fase 2: Material Didático Estruturado (Resumo da Matéria)

Probabilidade e Estatística (LEIC) - Material de Estudo Consolidado

1. Estatística Descritiva e Análise Exploratória de Dados

Medidas de Localização e Dispersão

- Média Amostral ($\bar{x}$):** Centro de massa dos dados. Sensível a *outliers*. $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- Mediana:** Valor central que divide a amostra ordenada ao meio. Robusta a *outliers*.
- Relação Média-Mediana e Assimetria:**
 - Assimetria Positiva (à direita):** Média > Mediana. A cauda direita da distribuição é mais longa.
 - Assimetria Negativa (à esquerda):** Média < Mediana. A cauda esquerda é mais longa.

Medidas de Dispersão e Variabilidade

- Variância Amostral (s^2):** Mede a dispersão quadrática em torno da média. $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

- **Desvio Padrão Amostral (\$s\$):** Raiz quadrada da variância. Tem as mesmas unidades que os dados originais.
- **Coefficiente de Variação (CV):** Medida adimensional de dispersão relativa. Útil para comparar a variabilidade de conjuntos de dados com médias muito diferentes. $CV = \frac{s}{\bar{x}}$

Outliers

- **Regra do Intervalo Interquartil (IQR):** Um valor é considerado *outlier* se:
 - $x < Q_1 - 1.5 \times IQR$ (Outlier inferior)
 - $x > Q_3 + 1.5 \times IQR$ (Outlier superior) Onde $IQR = Q_3 - Q_1$.

2. Teoria das Probabilidades

Probabilidade Condicionada e Independência

- **Probabilidade Condicionada:** Probabilidade de um evento A ocorrer dado que o evento B já ocorreu. $P(A|B) = \frac{P(A \cap B)}{P(B)}$
- **Teorema da Probabilidade Total:** Se $\{B_1, B_2, \dots, B_k\}$ é uma partição do espaço amostral, então: $P(A) = \sum_{i=1}^k P(A|B_i)P(B_i)$
- **Teorema de Bayes:** Permite inverter probabilidades condicionadas. $P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)}$ onde $P(A) = \sum_{j=1}^k P(A|B_j)P(B_j)$

3. Variáveis Aleatórias e Distribuições de Probabilidade

A. Distribuições Discretas

Distribuição de Poisson

- **Contexto:** Modela o **número de eventos** que ocorrem num intervalo de tempo ou espaço fixo (ex: acessos a um site por minuto, falhas por semana).
- **Parâmetro:** λ (taxa média de ocorrências). Se a taxa é dada para um período T , o parâmetro para um período T' é $\lambda' = \lambda \times \frac{T'}{T}$.
- **Função de Probabilidade:** $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$
- **Valor Esperado:** $E[X] = \lambda$
- **Variância:** $Var(X) = \lambda$
- **Relação com a Distribuição Exponencial:** Se o número de eventos segue Poisson(λ), o **tempo entre eventos consecutivos** segue uma distribuição Exponencial com parâmetro $\theta = 1/\lambda$ (na mesma unidade de tempo).

Distribuição Binomial

- **Contexto:** Modela o **número de sucessos** em n provas de Bernoulli independentes e com probabilidade de sucesso p constante.
- **Função de Probabilidade:** $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$

Distribuição Hipergeométrica

- **Contexto:** Modela o número de sucessos numa amostra de tamanho n retirada **sem reposição** de uma população finita de tamanho N que contém K sucessos.

B. Distribuições Contínuas

Distribuição Uniforme Contínua

- **Contexto:** Todos os valores no intervalo $[a, b]$ são igualmente prováveis.
- **Função Densidade de Probabilidade (f.d.p.):** $f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$
- **Valor Esperado:** $E[X] = \frac{a+b}{2}$
- **Variância:** $Var(X) = \frac{(b-a)^2}{12}$

Distribuição Exponencial

- **Contexto:** Modela o **tempo de espera** até ao próximo evento (ex: tempo entre avarias, tempo de serviço).
- **Parâmetro:** λ (taxa) ou $\theta = 1/\lambda$ (média).
- **Função Densidade de Probabilidade (f.d.p.):** $f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$
- **Função de Distribuição Acumulada (F.D.A.):** $F(x) = P(X \leq x) = 1 - e^{-\lambda x}$
- **Propriedade de Falta de Memória:** $P(X > t + s \mid X > s) = P(X > t)$.
- **Valor Esperado:** $E[X] = 1/\lambda$
- **Variância:** $Var(X) = 1/\lambda^2$

Distribuição Normal (Gaussiana)

- **Contexto:** Modelo central em Estatística. Descreve muitos fenómenos naturais e serve de base para a Inferência Estatística.
- **Parâmetros:** Média (μ) e Desvio Padrão (σ). Notação: $X \sim N(\mu, \sigma^2)$.
- **Normal Padrão (Reduzida):** $Z \sim N(0, 1)$.
- **Estandarização:** Para calcular probabilidades de $X \sim N(\mu, \sigma^2)$, converte-se para a Normal Padrão Z : $Z = \frac{X - \mu}{\sigma}$. Logo, $P(X \leq x) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$.
- **Quantis:** O valor z_{α} é tal que $P(Z > z_{\alpha}) = \alpha$.

4. Teorema do Limite Central (TLC)

- **Contexto:** Fundamental para a Inferência Estatística quando não se conhece a distribuição da população ou quando se trabalha com somas/médias de muitas variáveis.
- **Enunciado:** Se $X_1, X_2, \dots, X_n$ são variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com média μ e variância σ^2 (finita), então a **soma** $S_n = \sum X_i$ e a **média amostral** $\bar{X} = S_n/n$ terão distribuição **aproximadamente Normal** para n suficientemente grande ($n \geq 30$ é uma regra prática comum). $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{e} \quad S_n \sim N(n\mu, n\sigma^2)$
- **Aplicação:** Permite usar a distribuição Normal para calcular probabilidades sobre médias ou somas, mesmo que a população original não seja Normal (ex: tempos exponenciais, contagens Poisson).

5. Inferência Estatística

Estimação Pontual

- **Estimador da Média ($\hat{\mu}$):** $\hat{\mu} = \bar{x}$
- **Estimador da Variância ($\hat{\sigma}^2$):** $\hat{\sigma}^2 = s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$ [VERIFICAR: Por vezes é usado o estimador $S'^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$; os testes referem-se geralmente a $\hat{\sigma}$ como o desvio padrão amostral corrigido, s .]

Intervalos de Confiança (IC)

- **Interpretação:** Um IC a $(1-\alpha)100\%$ contém o verdadeiro valor do parâmetro populacional com uma confiança de $(1-\alpha)100\%$.
- 1. **IC para a Média μ (Variância σ^2 Conhecida):** $\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$
- 2. **IC para a Média μ (Variância σ^2 Desconhecida):** $\left[\bar{x} - t_{(n-1); 1-\alpha/2} \frac{s}{\sqrt{n}}, \bar{x} + t_{(n-1); 1-\alpha/2} \frac{s}{\sqrt{n}} \right]$ Onde $t_{(n-1); 1-\alpha/2}$ é o quantil da distribuição **t-Student** com $n-1$ graus de liberdade.
- 3. **IC para a Variância σ^2 (População Normal):** $\left[\frac{(n-1)s^2}{\chi^2_{(n-1); 1-\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{(n-1); \alpha/2}} \right]$ Onde $\chi^2_{(n-1); p}$ é o quantil da distribuição **Qui-Quadrado** com $n-1$ graus de liberdade.

Testes de Hipóteses

- **Elementos do Teste:**
 - **Hipótese Nula (H_0):** Afirmação a ser testada (geralmente de igualdade, " $=$ " ou " $\geq$ ").
 - **Hipótese Alternativa (H_1):** Afirmação que se suspeita ser verdadeira (" $\neq$ ", " $>$ ", " $<$ ").
 - **Nível de Significância (α):** Probabilidade máxima tolerada de cometer um **Erro Tipo I** (Rejeitar H_0 quando H_0 é verdadeira).
 - **p-value:** Probabilidade de observar um valor da estatística de teste tão ou mais extremo do que o observado, **assumindo que H_0 é verdadeira**.
- **Regra de Decisão:**
 - **Via Região Crítica:** Rejeitar H_0 se a **Estatística de Teste** pertencer à Região Crítica.
 - **Via p-value:** Rejeitar H_0 se **p-value $\leq \alpha$** .
- **Teste de Ajustamento de Shapiro-Wilk (Normalidade):**
 - **H_0 :** A amostra provém de uma população **Normal**.
 - **H_1 :** A amostra **não** provém de uma população Normal.
 - **Decisão:** Se **p-value $> \alpha$** , **não se rejeita H_0** , ou seja, é plausível assumir que os dados são Normais.

6. Regressão Linear Simples

- **Modelo:** $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, onde $\varepsilon_i \sim N(0, \sigma^2)$.
- **Objetivo:** Modelar a relação linear entre uma variável preditora (X) e uma variável resposta (Y).

Estimativas dos Mínimos Quadrados

- **Declive ($\hat{\beta}_1$):**
$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{n \sum x_i y_i - (\sum x_i)(\sum y_i)}{n \sum x_i^2 - (\sum x_i)^2}$$
- **Interceção ($\hat{\beta}_0$):**
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Medidas de Qualidade do Ajuste

- **Coefficiente de Correlação Linear (r ou R):** Mede a **direção e força** da relação linear. Varia entre -1 e 1.
$$R = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$
- **Coefficiente de Determinação (R^2):** Mede a **proporção da variabilidade de Y que é explicada pelo modelo** de regressão linear. Varia entre 0 e 1. Quanto mais próximo de 1, melhor o ajuste.
$$R^2 = \frac{\text{Variação Explicada}}{\text{Variação Total}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$
 No modelo simples, $R^2 = (R)^2$.

Inferência no Modelo (Significância da Regressão)

- **Teste ao Declive (β_1):**
 - H_0 : $\beta_1 = 0$ (Não existe relação linear entre X e Y).
 - H_1 : $\beta_1 \neq 0$ (Existe relação linear significativa).
- **Estatística de Teste:** $T = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}$, com distribuição t-Student com $n-2$ graus de liberdade sob H_0 .
- **Decisão:** Se $|T_{\text{obs}}| > t_{(n-2); 1-\alpha/2}$ ou se $p\text{-value} < \alpha$, rejeita-se H_0 e conclui-se que o modelo é significativo.

Lista de Termos-Chave

Probabilidade Condicionada, Teorema de Bayes, Média, Mediana, Variância, Desvio Padrão, Coeficiente de Variação, Outlier, Assimetria, Distribuição de Poisson, Distribuição Binomial, Distribuição Exponencial, Distribuição Uniforme, Distribuição Normal, Teorema do Limite Central, Estimativa Pontual, Intervalo de Confiança, t-Student, Qui-Quadrado, Nível de Significância, Hipótese Nula, Hipótese Alternativa, p-value, Região Crítica, Teste de Shapiro-Wilk, Regressão Linear Simples, Mínimos Quadrados, Coeficiente de Correlação, Coeficiente de Determinação.