


Estatística Descritiva

carlos.geraldes@isel.pt



- **Amostra** é um conjunto de elementos extraídos da população;
- Uma **sondagem** é um estudo estatístico que incide numa amostra;
- Um **censo** é um estudo estatístico que incide na totalidade da população;
- **População** é o conjunto de elementos sobre o qual incide o estudo (e.g. pessoas, animais, objetos) e que partilham uma ou mais características;
- **Unidade estatística** é um elemento da população;
- **Variável estatística** é a característica em estudo;
- Uma **observação** é uma característica que ocorre no estudo.

- **Amostra** é um conjunto de elementos extraídos da população;
- Uma **sondagem** é um estudo estatístico que incide numa amostra;
- Um **censo** é um estudo estatístico que incide na totalidade da população;
- **População** é o conjunto de elementos sobre o qual incide o estudo (e.g. pessoas, animais, objetos) e que partilham uma ou mais características;
- **Unidade estatística** é um elemento da população;
- **Variável estatística** é a característica em estudo;
- Uma **observação** é uma característica que ocorre no estudo.

- **Planificação** – Definição do processo para resolver o problema (como obter informações sobre as variáveis de interesse;
- **Recolha de dados** – Os dados podem ser adquiridos através de questionários, observação, experimentação e pesquisa bibliográfica;
- **Tratamento e organização dos dados** – Os dados podem ser apresentados por tabelas ou gráficos;
- **Análise e interpretação dos dados** – A informação deve ser condensada para que esta possa ser interpretada.

Cuidados a ter na formação da amostra:

- **Imparcialidade** – Todos os elementos devem ter a mesma oportunidade de fazer parte da amostra;
- **Representatividade** – Deve conter em proporção tudo o que a população possui, qualitativa e quantitativamente;
- **Tamanho** – Deve ser suficientemente grande de modo que as características da amostra se aproximem, tanto quanto possível das características da população.

- **Dado estatístico** - resultado de uma medição, contagem ou classificação, de uma dada característica de interesse, para cada elemento da amostra de n elementos, ou seja, um valor observado de uma variável aleatória X ;
- **Dado bruto** - $\rightarrow x_i$ - dado tal como é recolhido, antes de qualquer tratamento;
- **Dado ordenado** - $\rightarrow x_{(i)}$ - os dados recolhidos em bruto podem ser ordenados, usualmente por ordem crescente, resultando numa amostra ordenada. Esta ordenação é um tratamento estatístico.

- **Tabela de dados não classificados** - tabela onde se encontram organizados os dados não classificados (que não sofreram nenhum tratamento). Normalmente, os dados são organizados de forma a que as observações fiquem descritas em linha e as variáveis em coluna;
- **Tabela de frequências (dados agrupados ou classificados)** - tabela que resume os dados ordenados de forma a poderem ser interpretados - dados classificados ou agrupados.

Organização dos Dados

Exemplo de Tabela de Dados não classificados

ID	sepala.comp	sepala.largura	petala.comp	petala.largura	petala.area	variedade
1	5,1	3,5	1,4	0,2	Pequena	Setosa
2	4,9	3	1,4	0,2	Pequena	Setosa
3	4,7	3,2	1,4	0,2	Pequena	Setosa
4	4,6	3,1	1,5	0,2	Pequena	Setosa
5	6,5	2,8	4,6	1,5	Média	Versicolor
6	5,7	2,8	4,5	1,3	Média	Versicolor
7	6,3	3,3	4,7	1,6	Média	Versicolor
8	4,9	2,4	3,3	1	Média	Versicolor
9	6,9	3,1	5,1	2,3	Grande	Virginica
10	5,8	2,7	5,1	1,9	Grande	Virginica
11	6,8	3,2	5,7	2,3	Grande	Virginica
12	6,7	3,3	5,7	2,5	Grande	Virginica

- Cada linha corresponde a uma observação;
- Cada coluna corresponde a uma variável;
- Os dados encontram-se ordenados (não confundir com agrupados ou classificados) segundo a variável “petala.largura”;
- A coluna ID mostra o índice de cada observação tendo em conta a ordenação da coluna “petala.largura”.

É fundamental proceder-se à redução dos dados para uma melhor interpretação do fenómeno. Para tal é necessário:

- **Identificar** o tipo de escala de medição utilizada;
- Decidir qual o melhor método de **sumarização dos dados**.

- **Qualitativas** - Representam a informação que identifica alguma qualidade, categoria ou característica, não susceptível de medida, mas de classificação, assumindo várias modalidades. *Exemplo: Variedade da flor de lís;*
- **Quantitativas** - Representam a informação resultante de características suscetíveis de serem medidas, apresentando-se com diferentes intensidades. *Exemplo: Comprimento e largura das pétalas;*
 - **Discretas** - Assumem apenas valores inteiros. *Exemplo: Quantidade de pétalas;*
 - **Contínuas** - Assumem valores reais. *Exemplo: Comprimento das pétalas.*

Escalas de medição características das variáveis:

- **Binária** - Esta escala é usada em características com apenas dois estados possíveis, por exemplo, macho/ fêmea, presente/ausente;
- **Nominal** - As escalas nominais são meramente classificativas, permitindo descrever as variáveis ou designar os sujeitos, sem recurso à quantificação.
Exemplo: Variedade da flor de lis.;

Variáveis Qualitativas Nominais

Tabela de frequências de dados agrupados

Table: Distribuição de frequências (variável qualitativa)

Variedade	F_i	$f_i = \frac{F_i}{n}$
Setosa	4	$\frac{1}{3}$
Versicolor	4	$\frac{1}{3}$
Virginica	4	$\frac{1}{3}$
Total	$n = 12$	1

**Gráfico Circular
das espécies de flor de lis**





Gráfico de Barras



Ordinal - Nas escalas ordinais os indivíduos ou as observações distribuem-se segundo uma certa ordem, que pode ser crescente ou decrescente, permitindo estabelecerem-se diferenciações.

A escala ordinal é a avaliação de um fenómeno em termos da sua situação dentro de um conjunto de patamares ordenados, variando desde um patamar mínimo até um patamar máximo. Geralmente, designam-se os valores de uma escala.

Exemplo: Categorias da área da pétala: Pétala Grande; Pétala Média; Pétala Pequena.

Variáveis Qualitativas Ordinais

Tabela de frequências de dados agrupados

Table: Dados agrupados por frequências (variável qualitativa ordinal)

Área(categorias)	F_i	$\overline{F_i}$	$f_i = \frac{F_i}{n}$	$\overline{f_i} = \frac{\overline{F_i}}{n}$
Pequena	4	4	$\frac{1}{3}$	$\frac{1}{3}$
Média	4	8	$\frac{1}{3}$	$\frac{2}{3}$
Grande	4	12	$\frac{1}{3}$	1
Total	$n = 12$		1	

- **Intervalar ou de intervalo** - A escala intervalar é uma forma quantitativa de registar um fenómeno, medindo-o em termos da sua intensidade específica, ou seja, posicionando-o em relação a um valor conhecido o ponto zero;
Exemplo: Temperatura ($^{\circ}\text{C}$), onde não se pode assumir um ponto zero como ausência de temperatura.
- **Absoluta, razão ou de rácio** - A escala de razão é a mais completa e sofisticada das escalas. É uma quantificação produzida a partir da identificação de um ponto zero que é fixo e absoluto, representando, de facto, um ponto mínimo. Nesta escala, uma unidade de medida é definida em termos da diferença entre o ponto zero e uma intensidade conhecida. Nesta escala, além de ser possível quantificar as diferenças entre as medições, também estão garantidas certas propriedades matemáticas.
Exemplo: Comprimento e largura das pétalas e das sépalas.

Variáveis Quantitativas Discretas

Tabela de frequências de dados agrupados


Table: Dados agrupados por frequências (variável quantitativa discreta)

$\#Folhas$	F_i	$\overline{F_i}$	$f_i = \frac{n_i}{n}$	$\overline{f_i} = \frac{\overline{F_i}}{n}$
3	3	3	0,25	0,25
4	3	6	0,25	0,50
5	6	12	0,50	1
Total	$n = 12$		1	


Variáveis Quantitativas Discretas

Representações Gráficas

Gráfico de Linhas



Polígono de Frequências



Os valores de uma variável contínua podem ser agrupados em classes (intervalos):

- 1 Ordenar os valores amostrais $x_i \rightarrow x_{(i)}$;
- 2 Determinar a amplitude amostral $R = x_{(n)} - x_{(1)}$;
- 3 Definir as k classes ($k \rightarrow$ menor inteiro tal que $2^k \geq n$);
- 4 Amplitude das classes $h = \frac{R}{k}$ (valor arredondado por excesso);
- 5 Determinar $\epsilon = kh - R$ e fazer $L_1 = x_{(1)} - \frac{\epsilon}{2}$;
- 6 Construir as Classes:
 $C_1 =]L_1, L_1 + h] =]L_1, L_2]$,
 $C_2 =]L_2, L_2 + h] =]L_2, L_3]$,
(...)
 $C_k =]L_k, L_k + h] =]L_k, L_{k+1}]$, em que $L_{k+1} = x_{(n)} + \frac{\epsilon}{2}$.

Variáveis Quantitativas Contínuas

Tabela de dados agrupados em intervalos de classe

Variável de interesse: Comprimento da Pétala;


1,4 1,4 1,4 1,5 3,3 4,5 4,6 4,7 5,1 5,1 5,7 5,7

- $R = 5,7 - 1,4 = 4,3; n = 12 \Rightarrow k = 4;$
- $h = \frac{4,3}{4} = 1,075 \approx 1,08;$
- $\epsilon = 4 \times 1,08 - 4,3 = 0,02;$
- $L_1 = 1,40 - \frac{0,02}{2} = 1,39$

Table: Dados agrupados em intervalos de classe

Classes x_i	Ponto médio das classes x_i	F_i	$\overline{F}_i$	$f_i = \frac{F_i}{n}$	$\overline{f}_i = \frac{\overline{F}_i}{n}$
$]1,39; 2,47]$	1,93	4	4	$\frac{4}{12}$	$\frac{4}{12}$
$]2,47; 3,55]$	3,01	1	5	$\frac{1}{12}$	$\frac{5}{12}$
$]3,55; 4,63]$	4,09	2	7	$\frac{2}{12}$	$\frac{7}{12}$
$]4,63; 5,71]$	5,17	5	12	$\frac{5}{12}$	1
Total		$n = 12$		1	

Histograma do comprimento das pétalas da Flor de Lís



Variáveis Quantitativas Contínuas

Representação gráfica - histograma

Histograma Frequência Relativa





Gráfico de Densidade Empírica



Dados não classificados $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$

Dados classificados: $\bar{x} = \frac{\sum_{i=1}^k F_i x_i}{n} = \sum_{i=1}^k f_i x_i$

Vantagens:

- Facilidade de interpretação e cálculo e por isso muito utilizada;
- Utiliza toda a informação disponível;
- É uma quantidade matemática e susceptível de tratamento matemático.

Inconvenientes:

- É influenciada pelos valores extremos;
- Pode não corresponder a um valor concreto da variável;
- Em variáveis com distribuição assimétrica o seu valor não reflete realmente a tendência central.

Ordenados os elementos da amostra, esta medida corresponde ao valor (pertencente ou não à amostra) que a divide ao meio, isto é, 50% dos elementos da amostra são menores ou iguais à mediana e os outros 50% são maiores ou iguais à mediana

- Se n é ímpar, a mediana é o elemento que ocupa a posição central da amostra ordenada: $me = x_{(\frac{n+1}{2})}$
- Se n é par, a mediana é a média entre os dois elementos que ocupam a posição central da amostra ordenada: $me = \frac{x_{(\frac{n}{2})} + x_{(1+\frac{n}{2})}}{2}$
- Nos dados classificados em intervalos de classe, a classe mediana é aquela a que corresponde uma frequência relativa acumulada igual ou superior a 0,5.

Vantagens:

- tem interpretação intuitiva e directa
- nas variáveis com distribuição simétrica tem a mesma interpretação que a média
- Nas distribuições fortemente assimétricas é muito utilizada por não ser afectada por valores extremos
- nas variáveis ordenadas é uma medida de tendência central melhor que a média

Inconvenientes:

- é calculada mediante algoritmo
- não tem tratamento matemático simples realmente a tendência central.

Valor que surge com mais frequência se os dados são discretos, ou, o intervalo de classe com maior frequência se os dados são contínuos.

- Amodal – Se todos os valores que a variável pode tomar surgem com a mesma frequência;
- Unimodal – Se apenas um valor surge com maior frequência;
- Bimodal – Idem para dois valores;
- Multimodal – Idem para mais do que um valor.

Vantagens:

- Pode ser determinada em qualquer tipo de atributo, incluindo os medidos em escalas nominais;
- Não sofre influência de valores extremos.

Inconvenientes:

- Não existem garantias de ser um valor único em amostras muito pequenas pode haver tantas modas como valores;
- Não tem tratamento matemático simples.

Medidas de tendência não central

São medidas que tal como as anteriores nos dão a também a localização dos valores da variável mas não em termos centrais.

Quantil de ordem p ($0 < p < 1$)

Pode-se definir como sendo o valor tal que $100 \times p\%$ dos valores da amostra são $\leq Q_p$ e os restantes $100 \times (1 - p)\%$ são $\geq Q_p$. Dividem os dados em grupos com igual número de observações.


$Q_p = (1 - k)x_{(i)} + kx_{(i+1)}$, onde

$i = \lfloor np + 1 - p \rfloor$, $k = np + 1 - p - i$, $0 < p < 1$,

$x_{(i)}$ é o i -ésimo valor observado na amostra ordenada e $\lfloor a \rfloor$ representa a parte inteira de a .

Medidas de tendência não central

Quantil



Nota: Existem duas observações com o valor de 4,9

Os Quartis são os valores da variável que dividem a distribuição de frequências em 4 partes iguais.

- $Q_{\frac{1}{4}}$, o primeiro quartil, é um valor da variável com 25% de observações de valores inferiores e 75% superiores;
- $Q_{\frac{3}{4}}$, o terceiro quartil, é um valor da variável com 75% de observações de valores inferiores e 25% superiores.

Os Decis são 9 e dividem uma distribuição de frequências em 10 partes iguais.

Os Percentis são 99 e dividem uma distribuição de frequências em 100 partes iguais.

- Amplitude Total: $R = x_{(n)} - x_{(1)}$
- Amplitude inter-quartis (medida resistente): $IQ = Q_{\frac{3}{4}} - Q_{\frac{1}{4}}$
- Variância Amostral: Medida da variabilidade ou dispersão dos dados relativamente à média.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{\sum_{i=1}^n x_i^2 - n\bar{x}^2}{n-1}$$

- Desvio padrão amostral: $s = \sqrt{s^2}$
- Coeficiente de variação: Deve utilizar-se quando pretendemos comparar a dispersão entre duas amostras expressas em diferentes unidades de medida ou com médias amostrais diferentes.

$$C_v = 100\% \times \frac{s}{|\bar{x}|}$$

- Se $C_v \leq 15\%$, os dados apresentam uma variabilidade fraca;
 - Se $15\% < C_v < 30\%$, os dados apresentam uma variabilidade média;
 - Se $C_v \geq 30\%$, os dados apresentam uma variabilidade elevada.
- Coeficiente de variação resistente: $C_{vr} = 100\% \times \frac{IQ}{|M_e|}$

Exercicio

Para estudar o parque habitacional de determinada cidade quanto ao número de assoalhadas entrevistaram-se 270 famílias. Destas 50 tinham uma casa com 1 assoalhada, 60 com 2 assoalhadas, 80 com 3 assoalhadas, 50 com 4 assoalhadas, 20 com 5 assoalhadas e 10 com 6 assoalhadas.

- (a) Represente a distribuição de frequência utilizando um gráfico de barras.*
- (b) Determine e interprete os valores para a média, moda, mediana e coeficiente de variação.*

(a) Para que se possa construir um gráfico de barras, em primeiro lugar há que efetuar alguns passos intermédios, nomeadamente definir o seguinte:

População - parque habitacional de determinada cidade;

Unidade estatística - uma habitação;

Variável em estudo - nº de assoalhadas da habitação;

Tipo de variável: Quantitativa discreta;


Table: Tabela de frequências

#de assoalhadas	F_i	$\overline{F}_i$	$f_i = \frac{F_i}{n}$	$\overline{f}_i$
1	50	50	0,185	0,185
2	60	110	0,222	0,407
3	80	190	0,297	0,704
4	50	240	0,185	0,889
5	20	260	0,074	0,963
6	10	270	0,037	1
Total	$n = 270$		1	


Exercícios

Resolução

A partir da tabela obtemos o seguinte gráfico:



Polígono de Frequências



(b)

Table: Tabela de frequências

#de assoalhadas	F_i	$\overline{F}_i$	$f_i = \frac{F_i}{n}$	$\overline{f}_i$	$F_i x_i$	$F_i x_i^2$
1	50	50	0,185	0,185	50	50
2	60	110	0,222	0,407	120	240
3	80	190	0,297	0,704	240	720
4	50	240	0,185	0,889	200	800
5	20	260	0,074	0,963	100	500
6	10	270	0,037	1	60	360
Total	n = 270		1		770	2670

$$\bar{x} = \frac{\sum_{i=1}^k F_i x_i}{n} = \frac{770}{270} = 2,852 \text{ assoalhadas.}$$

Uma vez que $n = 270$ (n par) e considerando a amostra ordenada:

$$M_e = \frac{x(\frac{n}{2}) + x(\frac{n}{2} + 1)}{2} = \frac{x_{(135)} + x_{(136)}}{2} = 3 \text{ assoalhadas.}$$

$M_o = 3$ assoalhadas.

$$s^2 = \frac{\sum_{i=1}^k F_i x_i^2 - n \bar{x}^2}{n-1} = \frac{2670 - 270 \times 2,852^2}{269} = 1,762 \text{ assoalhadas}^2.$$

$$s = \sqrt{s^2} = 1,327 \text{ assoalhadas.}$$


$$C_v = \frac{s}{\bar{x}} \times 100\% = 46,5\%.$$

Uma vez que $C_v \geq 30\%$ significa que os dados apresentam uma variabilidade elevada.

Variáveis Quantitativas Contínuas

Representação gráfica - Dados não agrupados

- Oi - Valor abaixo do qual se considera ser outlier severo inferior;
- oi - Valor abaixo do qual se considera ser outlier moderado inferior;
- m - Menor valor da amostra que não é outlier;
- M - Maior valor da amostra que não é outlier;
- os - Valor abaixo do qual se considera ser outlier moderado superior;
- Os - Valor abaixo do qual se considera ser outlier severo superior;



Exercicio

Os resultados da análise ao teor em ferro, em mg de vinte amostras de um litro de água proveniente da rede pública de abastecimento de Lisboa são:

Table:

0,82	0,69	0,65	0,88	1,50	0,98	0,89	0,58	0,93	0,76
0,90	0,82	0,82	0,96	0,72	0,81	0,82	0,65	0,81	0,73

- (a) Determine a média, a moda e a mediana.*
- (b) Determine os três quartis, o segundo decil e o quadragésimo terceiro percentil.*
- (c) O que pode concluir quanto à existência de outliers nesta amostra?*
- (d) Determine a variância, o desvio padrão e o coeficiente de variação.*
- (e) Represente a distribuição de frequência utilizando um histograma.*
- (f) Determine a média, variância e desvio padrão a partir da tabela de frequências.*

(a) Unidade estatística - um litro de água;
Variável em estudo - teor em ferro;
Tipo de variável: Quantitativa contínua;
Começamos por ordenar a amostra:

Table:

0,58	0,65	0,65	0,69	0,72	0,73	0,76	0,81	0,81	0,82
0,82	0,82	0,82	0,88	0,89	0,90	0,93	0,96	0,98	1,50

Média: $\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{16,72}{20} = 0,836 \text{ mg/l.}$

Moda: O valor com maior frequência é $M_o = 0,820 \text{ mg/l.}$

Mediana: $M_e = Q_{\frac{1}{2}}$

$p = 0,5; n = 20; \Rightarrow n \times p = 10$

$i = \lfloor np + 1 - p \rfloor = \lfloor 10 + 1 - 0,5 \rfloor = \lfloor 10,5 \rfloor = 10$

$k = np + 1 - p - i = 0,5$

$Q_{\frac{1}{2}} = (1 - k)x_{(i)} + kx_{(i+1)} = 0,5x_{(10)} + 0,5x_{(11)} = 0,820 \text{ mg/l.}$

Em 50% das amostras provenientes da rede pública de abastecimento de Lisboa encontrou-se teor de ferro (em um litro de água) até 0,820 mg/l.

(b)

1º Quartil: $Q_{\frac{1}{4}}$

$$p = 0,25; n = 20; \Rightarrow n \times p = 5$$

$$i = \lfloor np + 1 - p \rfloor = \lfloor 5,75 \rfloor = 5$$

$$k = np + 1 - p - i = 0,75$$

$$Q_{\frac{1}{4}} = (1 - k)x_{(i)} + kx_{(i+1)} = 0,25x_{(5)} + 0,75x_{(6)} = 0,728 \text{ mg/l.}$$

Em 25% das amostras provenientes da rede pública de abastecimento de Lisboa encontrou-se teor de ferro (em um litro de água) até 0,728 mg/l.

3º Quartil: $Q_{\frac{3}{4}}$

$$p = 0,75; n = 20; \Rightarrow n \times p = 15$$

$$i = \lfloor np + 1 - p \rfloor = \lfloor 15,25 \rfloor = 15$$

$$k = np + 1 - p - i = 0,25$$

$$Q_{\frac{3}{4}} = (1 - k)x_{(i)} + kx_{(i+1)} = 0,75x_{(15)} + 0,25x_{(16)} = 0,893 \text{ mg/l.}$$

Em 75% das amostras provenientes da rede pública de abastecimento de Lisboa encontrou-se teor de ferro (em um litro de água) até 0,893 mg/l.

2º Decil: $Q_{\frac{2}{10}}$

$$p = 0,20; n = 20; \Rightarrow n \times p = 4$$

$$i = \lfloor np + 1 - p \rfloor = \lfloor 4,8 \rfloor = 4$$

$$k = np + 1 - p - i = 0,8$$

$$Q_{\frac{2}{10}} = (1 - k)x_{(i)} + kx_{(i+1)} = 0,2x_{(4)} + 0,8x_{(5)} = 0,714 \text{ mg/l.}$$

Em 20% das amostras provenientes da rede pública de abastecimento de Lisboa encontrou-se teor de ferro (em um litro de água) até 0,714 mg/l.

43º Percentil: $Q_{\frac{43}{100}}$

$$p = 0,43; n = 20; \Rightarrow n \times p = 8,6$$

$$i = \lfloor np + 1 - p \rfloor = \lfloor 9,17 \rfloor = 9$$

$$k = np + 1 - p - i = 0,17$$

$$Q_{\frac{43}{100}} = (1 - k)x_{(i)} + kx_{(i+1)} = 0,83x_{(9)} + 0,17x_{(10)} = 0,812 \text{ mg/l.}$$

Em 43% das amostras provenientes da rede pública de abastecimento de Lisboa encontrou-se teor de ferro (em um litro de água) até 0,812 mg/l.

(c) Amplitude Interquartílica: $IQ = Q_{\frac{3}{4}} - Q_{\frac{1}{4}}$

Pesquisa de outliers:

São considerados outliers os valores superiores a $Q_{\frac{3}{4}} + 1,5IQ = 1,140$ ou inferiores a

$Q_{\frac{1}{4}} - 1,5IQ = 0,48$.

São considerados outliers severos os valores superiores a $Q_{\frac{3}{4}} + 3IQ = 1,388$ ou inferiores a

$Q_{\frac{1}{4}} - 3IQ = 0,233$.

Verifica-se que só existe um outlier ($x_{(20)} = 1,5$), sendo este severo.

(d) Variância: $s^2 = \frac{\sum_{i=1}^n x_i^2 - n\bar{x}^2}{n-1} = 0,036 \text{ (mg/l)}^2$.

Desvio Padrão: $s = \sqrt{0,036} = 0,190 \text{ mg/l}$.


$C_v = \frac{s}{\bar{x}} \times 100\% = 22,69\%$. Os dados apresentam uma variabilidade média.

(e) Iremos seguir a seguinte metodologia para resolução deste exercício:

- 1 Ordenar os valores amostrais $x_i \rightarrow x_{(i)}$;
Os valores amostrais já se encontram ordenados.
- 2 Determinar a amplitude amostral $R = x_{(n)} - x_{(1)}$;
Neste caso temos que $R = 1,50 - 0,58 = 0,92$
- 3 Definir as k classes ($k \rightarrow$ menor inteiro tal que $2^k \geq n$);
Sendo $n = 20$ observações, então temos que $k = 5$ classes.
- 4 Amplitude das classes $h = \frac{R}{k}$ (valor arredondado por excesso);
Neste caso, $h = \frac{0,92}{5} = 0,19$ (valor arredondado por excesso).
- 5 Determinar $\epsilon = kh - R$ e fazer $L_1 = x_{(1)} - \frac{\epsilon}{2}$;
 $\epsilon = 5 \times 0,19 - 0,92 = 0,03$
 $L_1 = 0,58 - 0,015 = 0,565$.
- 6 Construir as Classes:
 $C_1 =]0,565; 0,565 + 0,190] =]0,565; 0,755]$
 $C_2 =]0,755; 0,755 + 0,190] =]0,755; 0,945]$
 $C_3 =]0,945; 0,945 + 0,190] =]0,945; 1,135]$
 $C_4 =]1,135; 1,135 + 0,190] =]1,135; 1,325]$
 $C_5 =]1,325; 1,325 + 0,190] =]1,325; 1,515]$

Table: Tabela de frequências

Classes	x_i	F_i	$\overline{F}_i$	$f_i = \frac{F_i}{n}$	$\overline{f}_i$	$F_i x_i$	$F_i x_i^2$
]0, 565; 0, 755]	0,660	6	6	0,3	0,3	3,96	2,6136
]0, 755; 0, 945]	0,850	11	17	0,55	0,85	9,35	7,9475
]0, 945; 1, 135]	1,040	2	19	0,1	0,95	2,08	2,1632
]1, 135; 1, 325]	1,230	0	19	0	0,95	0	0
]1, 325; 1, 515]	1,420	1	20	0,05	1,00	1,42	2,0164
Total		$n = 20$		1		16,81	14,7407



(f) Relativamente à média, variância e desvio padrão de valores agrupados temos:

$$\bar{x} = \frac{\sum_{i=1}^{k=5} F_i x_i}{n} = \frac{16,81}{20} = 0,8405 \text{ mg/l.}$$

$$s^2 = \frac{\sum_{i=1}^{k=5} F_i x_i^2 - n\bar{x}^2}{n-1} = \frac{14,7407 - 20 \times 0,8405^2}{19} = 0,032205 \text{ mg/l}^2.$$

$$s = \sqrt{s^2} = 0,1794575 \text{ mg/l.}$$

Exercicio

Numa experiência para verificar a resistência de uma fibra textil, produzida de acordo com uma nova tecnologia, os fios de uma fábrica são submetidos a tracção e pressão, o que provoca a sua ruptura e essa informação é registada.

Obtiveram-se, em unidades apropriadas, os seguintes valores.

8,9 10,2 7,5 8,4 9,3 14,0 9,0 7,9 8,8 9,5 5,6

Usando o software estatístico R foi analisada esta amostra e obteve-se o seguinte output:

```
Resistencia_fibras
Min.   : 5.600
1st Qu.: 8.150
Median : 8.900
Mean   : 9.009
3rd Qu.: 9.400
Max.   :14.000
```

(a) Interprete os resultados obtidos para esta amostra.

(b) O que pode concluir quanto à existência de outliers nesta amostra?

(a) Consideremos a variável em estudo:

X - "Resistência de uma fibra textil"

Trata-se de uma variável quantitativa contínua numa escala de razão.

Resistência mínima - $\min\{x_i\} = 5,60$

Resistência máxima - $\max\{x_i\} = 14,00$

Média: $\bar{x}_i = 9,01$. A resistência média é 9,01 unidades.

1º Quartil: $Q_{\frac{1}{4}} = 8,15$ - 25% das amostras apresentam uma resistência até 8,15 unidades.

Mediana ou 2º Quartil: $M_e = Q_{\frac{1}{2}} = 8,90$ - 50% das amostras apresentam uma resistência até 8,90 unidades.

3º Quartil: $Q_{\frac{3}{4}} = 9,40$ - 75% das amostras apresentam uma resistência até 9,40 unidades.

(b) Em primeiro lugar, há que ordenar a amostra:

5,6	7,5	7,9	8,4	8,8	8,9	9,0	9,3	9,5	10,2	14,0
-----	-----	-----	-----	-----	-----	-----	-----	-----	------	------

1º Quartil: $Q_{\frac{1}{4}}$

$$p = 0,25; n = 11; \Rightarrow n \times p = 2,75$$

$$i = \lfloor np + 1 - p \rfloor = 3$$

$$k = np + 1 - p - i = 0,5$$

$$Q_{\frac{1}{4}} = (1 - k)x_{(i)} + kx_{(i+1)} = 0,5x_{(3)} + 0,5x_{(4)} = 8,15 \text{ unidades.}$$

25% das fibras apresentam uma resistência até 8,15 unidades, o que pode ser confirmado pelo output do R.

3º Quartil: $Q_{\frac{3}{4}}$

Pela leitura do output do R temos que $Q_{\frac{3}{4}} = 9,400$.

Amplitude Interquartílica:

$$IQ = Q_{\frac{3}{4}} - Q_{\frac{1}{4}} = 1,25$$

Pesquisa de outliers:

São considerados outliers os valores superiores a $Q_{\frac{3}{4}} + 1,5IQ = 11,275$ ou inferiores a

$$Q_{\frac{1}{4}} - 1,5IQ = 6,275.$$

São considerados outliers severos os valores superiores a $Q_{\frac{3}{4}} + 3IQ = 13,15$ ou inferiores a

$$Q_{\frac{1}{4}} - 3IQ = 4,4.$$

Verifica-se a existência de um outlier inferior moderado ($x = 5,6$) e um outlier superior severo ($x = 14,0$).


Coeficiente de assimetria

Mede o desvio que a distribuição de frequências apresenta relativamente à reta vertical que passa pela abcissa correspondente ao valor da média aritmética.


$$C_a = \frac{m_3}{s^3}, \text{ em que } m_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3$$

- $C_a < 0$: distribuição assimétrica negativa
- $C_a = 0$: distribuição simétrica
- $C_a > 0$: distribuição assimétrica positiva


Medidas de Assimetria



$Média > Mediana > Moda$
Assimétrica Positiva
ou enviesada à direita



$Média = Mediana = Moda$
Simétrica




$Média < Mediana < Moda$
Assimétrica Negativa
ou enviesada à esquerda

Coeficiente de achatamento


Mede o grau de achatamento de uma curva simétrica em relação à curva normal.

$$C_c = \frac{m_4}{s^4}, \text{ em que } m_4 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4$$


- $C_c < 0$: curva Platicúrtica. Distribuição mais achatada e com uma cauda menos pesada que a distribuição normal.
- $C_c = 0$: curva Mesocúrtica. Distribuição com achatamento igual ao da distribuição normal.
- $C_c > 0$: curva Leptocúrtica. Distribuição mais esguia e com uma cauda mais pesada que a distribuição normal.



Leptocurtica



Mesocurtica



Platicurtica

Exercicio

Determinada empresa fornecedora de energia elétrica dividiu um país em duas regiões. Na região 1 foi recolhida uma amostra relativa ao consumo diário de energia elétrica, em milhares de MWh e foi analisada usando o software estatístico R, tendo-se obtido o seguinte output:

```
Energia_electrica
nobs      10.00000
NA's      0.00000
Minimum   86.10000
Maximum   118.20000
1. Quartile 103.25000
3. Quartile 114.42500
Mean      106.87000
Median    111.85000
Sum        1068.70000
SE Mean    3.64449
LCL Mean   98.62568
UCL Mean   115.11431
Variance    132.82011
Stdev      11.524761
Skewness   -0.862665
Kurtosis   -0.977304
```

Relativamente à região 2, foi recolhida uma amostra relativa ao consumo diário de energia elétrica, em milhares de MWh, tendo-se obtido os seguintes resultados:

$$\sum_{i=1}^{10} x_i = 4583$$

$$\sum_{i=1}^{10} x_i^2 = 2104171$$

- (a) Interprete os resultados obtidos para a amostra da região 1. Relacione a Média e a Mediana com a assimetria da distribuição amostral.*
- (b) Determine a média e o desvio padrão do consumo diário de energia elétrica da região 2. Interprete os resultados obtidos.*
- (c) Qual das duas regiões apresenta maior variabilidade relativamente ao consumo diário de energia? Justifique.*

(a) Consideremos a variável X_1 consumo diário de energia elétrica em milhares de MWh da região 1. Trata-se de uma variável quantitativa contínua de razão.

Número de observações: $n_1 = 10$.

Número de observações em falta: 0

Consumo mínimo de energia elétrica: $\min\{x_{1i}\} = 86,1$ milhares de MWh.

Consumo máximo de energia elétrica: $\max\{x_{1i}\} = 118,2$ milhares de MWh.

1º Quartil: $Q_{\frac{1}{4}} = 103,25$ milhares de MWh. Em 25% das observações registou-se um valor de consumo até 103,25 milhares de MWh.

2º Quartil ou Mediana: $Q_{\frac{2}{4}} = 111,85$ milhares de MWh. Em 50% das observações registou-se um valor de consumo até 111,85 milhares de MWh.

3º Quartil: $Q_{\frac{3}{4}} = 114,425$ milhares de MWh. Em 75% das observações registou-se um valor de consumo até 114,425 milhares de MWh.

Média: $\bar{x}_1 = 106,87$ milhares de MWh. O consumo médio da região 1 foi de 106,87 milhares de MWh.

Soma de todos os valores observados $\sum_{i=1}^{10} x_{1i} = 1068,70$.

Erro padrão: $\frac{s_1}{\sqrt{n_1}} = \frac{11,524761}{\sqrt{10}} = 3,644449$.

Limite inferior para o intervalo de confiança a 95% para o valor médio: 98,63

Limite superior para o intervalo de confiança a 95% para o valor médio: 115,11

Intervalo de confiança a 95% para o valor médio:]98,63; 115,11[

Variância: $s_1^2 = (132,820111)^2$ (milhares de MWh)²

Desvio padrão: $s_1 = 11,524761$ milhares de MWh. Os dados têm uma variabilidade em relação à média de 11,524761 milhares de MWh.

Coeficiente de assimetria: $C_a = \frac{m_3}{s_3} = -0,862665$ (distribuição assimétrica negativa).

Coeficiente de achatamento: $C_c = \frac{m_4}{s_4} = -0,977304$ (curva platicúrtica).

Pode-se considerar que a distribuição é assimétrica negativa tendo em conta que a Média é inferior à Mediana.

(b) Considerando a variável X_2 - Consumo diário da região 2 em milhares de MWh. Trata-se de uma variável quantitativa contínua de razão.

Média: $\bar{x}_2 = \frac{\sum_{i=1}^n x_{2i}}{n} = 458,3$ em milhares de MWh.

Variância: $s_2^2 = \frac{\sum_{i=1}^n x_{2i}^2 - n\bar{x}_2^2}{n-1} = 420,2$ (milhares de MWh)².

Desvio Padrão: $s_2 = \sqrt{420,2} = 20,5$ milhares de MWh.

Os dados têm uma variabilidade em relação à média de 20,5 milhares de MWh.

(c) Região 1: $C_{v1} = \frac{s_1}{|\bar{x}_1|} \times 100\% = 10,78\%$.

Região 2: $C_{v2} = \frac{s_2}{|\bar{x}_2|} \times 100\% = 4,47\%$.

A região 1 apresenta uma maior variabilidade que a região 2.

Ambas apresentam uma variabilidade fraca ($< 15\%$) indicando baixo grau de dispersão.

Exercicio


Um ficheiro contém 16 imagens dos dígitos 0 e 1 manuscritos (8 de cada grupo). Cada linha do ficheiro corresponde a uma e uma só dessas imagens. Na primeira coluna, encontra-se descrito o ID de uma imagem correspondente a um dígito. Na segunda podemos consultar o dígito a que determinada linha diz respeito (Se pertence ao grupo 1 ou 0). As restantes colunas (256 variáveis) correspondem, respetivamente, aos $(16 \times 16 = 256)$ píxeis da imagem em questão, sendo que o primeiro píxel do canto superior esquerdo (da imagem) corresponde à terceira coluna (do ficheiro) e assim por diante (o píxel 16 corresponde à coluna 18 e o primeiro píxel da segunda linha da imagem corresponderá à coluna 19).

IDImagem	Dígito	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13
1	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	0.5100	-0.2130	-1.0000	-1.0000	-1.0000	-1.0000
2	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.4540	0.8790	-0.7450	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000
3	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.9090	0.8010	-0.8990	-1.0000	-1.0000	-1.0000
4	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.8770	0.2330	1.0000	0.9960	0.1160	-0.8960	-1.0000	-1.0000
6	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.9980	0.6130	-0.3850	-1.0000	-1.0000	-1.0000	-1.0000
7	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	0.4570	-0.2190	-1.0000	-1.0000	-1.0000	-1.0000
8	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.9900	0.0190	0.6400	-0.5530	-0.9990	-1.0000	-1.0000	-1.0000
9	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	0.2540	0.2410	-0.9290	-1.0000	-1.0000	-1.0000	-1.0000
10	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.5820	0.8490	0.2090	-1.0000	-1.0000	-1.0000
11	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.7660	0.9600	-0.5280	-1.0000	-1.0000	-1.0000	-1.0000
12	1	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	0.2840	0.6540	-1.0000	-1.0000	-1.0000	-1.0000
13	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	0.1000	0.4520	-0.6650	-0.3580	-0.2090	-0.9740	-1.0000	-1.0000
14	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.3200	0.7310	-0.6570	-1.0000	-1.0000	-1.0000	-1.0000
15	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.9910	-0.5760	0.2530	1.0000	0.8520	-0.1920	-0.9740	-1.0000
16	0	-1.0000	-1.0000	-1.0000	-1.0000	-0.9240	0.1980	0.2490	0.9530	0.6730	-0.6190	-1.0000	-1.0000	-1.0000
17	0	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-1.0000	-0.1210	0.8700	-0.3080	-0.9970	-1.0000	-1.0000	-1.0000


Exercicio

Cada pixel pode tomar um valor correspondente a uma escala quantitativa de tons laranjas e que vão de -1 a +1, em que -1 corresponde à cor vermelha e +1 à cor amarela. Os valores intermédios dizem respeito às tonalidades intermédias de laranja.

Como exemplo, apresenta-se as imagens do dígito "0" respeitante à imagem com o ID 2 e do dígito "1" correspondente à imagem com o ID 10.



Dígito 0



Dígito 1

Exercicio

Dos valores da amostra, relativamente, aos pixels P1, P57 e P90, resultaram as seguintes caixas de bigodes. Qual destes pixels apresenta-se como sendo o melhor candidato para discriminar os dígitos manuscritos do grupo 0 dos do grupo 1?

