



Lista de exercícios propostos n.º 06: Correlação e regressão linear

Exercício 1.

Suponha que, para analisar o consumo de combustível, um automóvel efectuou 7 viagens, tendo-se registado a distância percorrida em km e o consumo em litros, obtendo-se, então, os 7 pares de valores seguintes:

x_i : consumo (litros)	2	3	5	9	12	14	18
y_i : distância percorrida (km)	20	40	80	120	160	200	250

- Esboce o diagrama de dispersão dos pontos (x_i, y_i) . O que pode concluir a partir da sua análise?
- Determine a covariância linear amostral existente entre as variáveis e interprete-a.
- Determine o coeficiente de correlação linear amostral e interprete-o.
- Considere um modelo de regressão linear simples. Obtenha a estimativa dos mínimos quadrados dos coeficientes da recta de regressão de Y sobre x . Identifique a respectiva equação da recta de regressão e desenhe-a no gráfico. Caso faça sentido, interprete o significado das estimativas dos coeficientes da recta de regressão.
- Determine SQE , SQT e SQR .
- Calcule o coeficiente de determinação linear amostral e tire conclusões acerca da qualidade do ajuste.
- Estime pontualmente a distância, em km, quando o consumo é de 1 litro, de 4 litros e de 12 litros. Comente a fiabilidade das estimativas efectuadas. Caso seja possível, determine o valor da estimativa do erro que cometeu.
- Foi utilizado o software estatístico R para determinar as estimativas dos erros de estimação ou resíduos, tendo-se obtido os seguintes valores:

$$e_1 = -6,0912698; \quad e_2 = -0,1190476; \quad e_3 = 11,8253968;$$

$$e_4 = -4,2857143; \quad e_5 = -6,3690476; \quad e_6 = 5,5753968;$$



$$e_7 = -0,5357143.$$

Em seguida, foi usando novamente o software estatístico R para realizar o teste de ajustamento de Kolmogorov-Smirnov com correcção de Lilliefors e o teste de ajustamento de Shapiro-Wilk aos valores obtidos para as estimativas dos erros de estimação e obtiveram-se os seguintes outputs:

Lilliefors (Kolmogorov-Smirnov) normality test	Shapiro-Wilk normality test
data: resid(lm(y ~ x))	data: resid(lm(y ~ x))
D = 0.2214, p-value = 0.3759	W = 0.89434, p-value = 0.2981

Com base nos resultados obtidos para o teste de ajustamento de Kolmogorov-Smirnov com correcção de Lilliefors e para o teste de ajustamento de Shapiro-Wilk, averigue se a distribuição dos erros de estimação pode ser considerada normal. Use um nível de significância de 5%.

- Determine um intervalo de confiança a 95% para a verdadeira distância percorrida, por cada litro a mais de consumo.
- Estime pontualmente e através de um intervalo de confiança a 95%, a distância percorrida, em km, para um consumo de 10 litros.
- Utilizando um nível de significância de 5%, teste a significância do modelo de regressão.
- Para um nível de significância de 5%, teste a hipótese da distância percorrida, em km, aumentar pelo menos 15 unidades por cada litro a mais de consumo.
- Teste, ao nível de significância de 1%, se a verdadeira ordenada na origem da recta de regressão populacional é igual a 0.



(n) Confirme o resultado obtido nas alíneas anteriores analisando o seguinte output do software estatístico R:

```
Call:
lm(formula = y ~ x)

Residuals:
    1      2      3      4      5      6      7
-6.0913 -0.1190 11.8254 -4.2857 -6.3690  5.5754 -0.5357

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -1.9643      5.2612  -0.373    0.724
x              14.0278      0.4975  28.199 1.05e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.311 on 5 degrees of freedom
Multiple R-squared:  0.9938, Adjusted R-squared:  0.9925
F-statistic: 795.2 on 1 and 5 DF, p-value: 1.05e-06
```

Analysis of Variance Table

```
Response: y
      Df Sum Sq Mean Sq F value    Pr(>F)
x         1  42504    42504   795.18 1.05e-06 ***
Residuals  5     267         53
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Exercício 2.

A evaporação dos solventes que se usam nas tintas depende da humidade ambiente. O conhecimento desta relação poderá ser útil para melhorar a qualidade da operação de pintura e reduzir os seus custos. Assim, foi conduzido um estudo para examinar a relação entre a humidade relativa ambiente, em %, a variável aleatória x , e a quantidade de um determinado solvente evaporado durante a pintura, em %, a variável aleatória, Y , e obtiveram-se os seguintes resultados:

$$\sum_{i=1}^{20} x_i = 1050; \quad \sum_{i=1}^{20} y_i = 190;$$

$$\sum_{i=1}^{20} x_i^2 = 60000; \quad \sum_{i=1}^{20} y_i^2 = 2000; \quad \sum_{i=1}^{20} x_i y_i = 9600.$$

- Determine os coeficientes da recta de regressão e interprete os resultados obtidos.
- Determine o coeficiente de determinação amostral e tire conclusões acerca da qualidade do ajuste.

Exercício 3.

De acordo com estudos realizados pelo Centro para a Prevenção e Controlo de Doenças dos Estados Unidos da América (EUA), a mortalidade entre adultos fumadores, de ambos os sexos, é cerca de três vezes maior do que entre adultos não fumadores e o tabagismo é responsável por uma em cada cinco mortes nos EUA a cada ano. Estima-se que a esperança de vida dos fumadores é pelo menos dez anos inferior à esperança de vida dos não fumadores e considera-se que deixar de fumar antes dos quarenta anos, reduz o risco de morte por doença relacionada com o tabagismo em cerca de 90%. Com o objectivo de avaliar se existe uma relação entre a esperança de vida e o número de cigarros fumados registaram-se, para 15 adultos de ambos os sexos, o número de cigarros fumados por dia, x , e os anos de vida, Y . Do estudo desta amostra obtiveram-se os seguintes resultados:

$$\sum_{i=1}^{15} x_i = 292; \quad \sum_{i=1}^{15} y_i = 1103;$$

$$\sum_{i=1}^{15} x_i^2 = 7840; \quad \sum_{i=1}^{15} y_i^2 = 82791; \quad \sum_{i=1}^{15} (x_i - \bar{x})(y_i - \bar{y}) = -1356,733.$$

- Determine o coeficiente de correlação linear amostral e interprete-o.



- (b) Considere um modelo de regressão linear simples. Obtenha a estimativa dos mínimos quadrados dos coeficientes da recta de regressão de Y sobre x . Indique a respectiva equação da recta de regressão. Caso faça sentido, interprete o significado das estimativas dos coeficientes da recta de regressão.
- (c) Determine o coeficiente de determinação linear amostral e tire conclusões acerca da qualidade do ajuste.




Soluções:

Exercício 1.

(a) Sejam as variáveis aleatórias:

- x - “consumo de combustível, em litros”;
- Y - “distância percorrida, em km”.

Tem-se o diagrama de dispersão:



Podemos concluir que existe uma correlação linear positiva (quase perfeita), ou seja, ambas as variáveis tendem a variar no mesmo sentido.



(b) Vamos construir a tabela seguinte que facilita os cálculos do exercício:

	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
	2	20	4	400	40
	3	40	9	1600	120
	5	80	25	6400	400
	9	120	81	14400	1080
	12	160	144	25600	1920
	14	200	196	40000	2800
	18	250	324	62500	4500
Total	63	870	783	150900	10860

Tem-se:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{63}{7} = 9$$

e

$$\bar{y} = \frac{\sum_{i=1}^n y_i}{n} = \frac{870}{7} = 124,29.$$

O valor da covariância é dado por:

$$\begin{aligned} \text{cov}[x, y] &= \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{n-1} = \frac{s_{xy}}{n-1} = \\ &= \frac{10860 - 7 \times 9 \times 124,29}{7-1} = \frac{3029,73}{6} = \\ &= 504,955. \end{aligned}$$

Podemos concluir que existe uma relação linear positiva, ou seja, ambas as variáveis tendem a variar no mesmo sentido.

(c) O valor do coeficiente de correlação linear amostral é dado por:

$$r = \frac{\text{cov}[x, y]}{s_x s_y},$$

onde s_x e s_y são os desvios padrão corrigidos das variáveis X e Y , respectivamente. Tem-se:

$$s_x = \sqrt{\frac{\sum_{i=1}^n x_i^2 - n \bar{x}^2}{n-1}} = \sqrt{\frac{783 - 7 \times 9^2}{6}} = 6$$



e

$$s_y = \sqrt{\frac{\sum_{i=1}^n y_i^2 - n \bar{y}^2}{n-1}} = \sqrt{\frac{150900 - 7 \times (124,29)^2}{6}} = 84,4235.$$

Logo

$$r = \frac{\text{cov}[x, y]}{s_x s_y} = \frac{504,955}{6 \times 84,4235} = 0,9969.$$

Também podemos calcular o coeficiente de correlação linear usando a fórmula:

$$r = \frac{s_{xy}}{\sqrt{s_{xx} s_{yy}}}.$$

Tem-se:

$$s_{xx} = \sum_{i=1}^7 x_i^2 - 7 \bar{x}^2 = 783 - 7 \times 9^2 = 216$$

e

$$s_{yy} = \sum_{i=1}^7 y_i^2 - 7 \bar{y}^2 = 150900 - 7 \times 124,29^2 = 42763,97$$

pelo que

$$r = \frac{s_{xy}}{\sqrt{s_{xx} s_{yy}}} = \frac{3029,73}{\sqrt{216 \times 42763,97}} = 0,9969.$$

Podemos concluir que existe uma correlação linear positiva quase perfeita entre as variáveis.

(d) Os coeficientes da recta de regressão são dados por:

$$b = \frac{s_{xy}}{s_{xx}} = 14,027$$

e

$$a = \bar{y} - b \bar{x} = -1,953.$$


Obtemos assim a equação da recta de regressão:

$$\hat{y}_i = a + b x_i = -1,953 + 14,027 x_i.$$

- Interpretação do declive da recta, b : quando o consumo aumenta um litro, a distância percorrida aumenta 14,027 km;
- Interpretação da ordenada na origem, a : o valor de a representa a distância percorrida quando o consumo é nulo. Neste caso esta interpretação não faz sentido porque a distância percorrida não pode ser negativa.



Podemos agora apresentar um diagrama de dispersão com a representação da recta ajustada ou recta de regressão:



(e) Tem-se:

$$SQE = s_{yy} - \frac{s_{xy}^2}{s_{xx}} = 267,378;$$

$$SQT = s_{yy} = 42763,97;$$

$$SQR = \frac{s_{xy}^2}{s_{xx}} = 42496,592.$$

(f) Tem-se:

$$r^2 = \frac{s_{xy}^2}{s_{xx}s_{yy}} = \frac{(3029,73)^2}{216 \times 42763,97} = 0,9937$$

ou

$$r^2 = \frac{SQR}{SQT} = \frac{42496,592}{42763,97} = 0,9937.$$

Cerca de 99,37% da variabilidade de Y , distância percorrida em km, é explicada à custa da variável x , consumo em litros.



(g) Sendo a recta de regressão dada por:

$$\hat{y}_i = a + bx_i = -1,953 + 14,027x_i,$$

tem-se:

- Para $x_i = 1$ tem-se $\hat{y}_i = -1,953 + 14,027 \times 1 = 12,074$ km. A estimativa para a distância, em km, quando o consumo é 1 litro é de 12,074 km.
- Para $x_i = 4$ tem-se $\hat{y}_i = -1,953 + 14,027 \times 4 = 54,155$ km. A estimativa para a distância, em km, quando o consumo é 4 litros é de 54,155 km.
- Para $x_i = 12$ tem-se $\hat{y}_i = -1,953 + 14,027 \times 12 = 166,371$ km. A estimativa para a distância, em km, quando o consumo é 12 litros é de 166,371 km, com um erro da estimativa dado por $e_5 = y_5 - \hat{y}_5 = 160 - 160,371 = -6,371$.

Nos dois primeiros casos não é possível determinar as estimativas dos erros cometidos ao efectuar as estimativas porque não são valores de consumo observados.

Note-se ainda que quando o ajustamento linear é “razoável”, a recta de regressão obtida pode ser utilizada para prever os valores de y , com base em valores de x . Se $x \in [\min_{i=1,\dots,n} x_i; \max_{i=1,\dots,n} x_i]$ o valor estimado para y será “bom”. Caso contrário, o valor estimado para y deve ser considerado com algum “cuidado” pois poderá não ser completamente fiável (erro de extrapolação). Assim, a estimativa obtida para o valor $x_i = 1$ deve ser considerada com algum cuidado, uma vez que $1 \notin [2; 18]$.

(h) Para averiguar se a distribuição de valores dos erros de estimação pode ser considerada normal, com um nível de significância de 5%, podemos realizar um teste de Kolmogorov-Smirnov com correcção de Lilliefors ou um teste de Shapiro-Wilk.

– Formulação das hipóteses:

$$\begin{cases} H_0 : \text{Os valores dos erros de estimação são provenientes} \\ \quad \text{de uma população com distribuição normal} \\ H_1 : \text{Os valores dos erros de estimação são provenientes} \\ \quad \text{de uma população com distribuição diferente da} \\ \quad \text{distribuição normal} \end{cases};$$



- *Nível de significância:* $\alpha = 0,05$;
- *Dimensão da amostra:* $n = 7$;
- *Valor da estatística de teste:*
 - * *Teste de ajustamento de Kolmogorov-Smirnov com correcção de Lilliefors:* $D_0 = 0,2214$;
 - * *Teste de ajustamento de Shapiro-Wilk:* $W_0 = 0,89434$.
- *Valor do p – value:*
 - * *Teste de ajustamento de Kolmogorov-Smirnov com correcção de Lilliefors:* p – value = 0,3759;
 - * *Teste de ajustamento de Shapiro-Wilk:* p – value = 0,2981.
- *Valor crítico tabelado para $n = 7$ e $\alpha = 0,05$:*
 - * *Teste de ajustamento de Kolmogorov-Smirnov com correcção de Lilliefors:* $D_{crítico; 0,05} = 0,300$;
 - * *Teste de ajustamento de Shapiro-Wilk:* $W_{crítico; 0,05} = 0,803$.
- *Tomada de decisão:*
 - * *Teste de ajustamento de Kolmogorov-Smirnov com correcção de Lilliefors:* Dado que

$$D_0 = D_{observado} = 0,2214 < 0,300 = D_{crítico; 0,05}$$

ou que

$$\alpha = 0,05 < 0,3759 = p - \text{value},$$

, não se deve rejeitar H_0 ao nível de significância de 5%, ou seja, não existe evidência estatística suficiente para rejeitar que os valores dos erros de estimação são provenientes de uma população com distribuição normal.

- * *Teste de ajustamento de Shapiro-Wilk:* Dado que

$$W_0 = W_{observado} = 0,89434 > 0,803 = W_{crítico; 0,05}$$


ou que

$$\alpha = 0,05 < 0,2981 = p - \text{value},$$

não se deve rejeitar H_0 ao nível de significância de 5%, ou seja, não existe evidência estatística suficiente para rejeitar que os valores dos erros de estimação são provenientes de uma população com distribuição normal.




Podemos obter um gráfico de comparação de quantis entre a distribuição empírica e a distribuição normal, tentando através dele avaliar, de uma forma meramente visual, se a variável em estudo segue uma distribuição normal. Nesse gráfico iremos representar pares ordenados dos quantis da distribuição empírica e da distribuição normal, usada como distribuição para comparação, obtendo-se:



Como se pode verificar, pela observação do gráfico de comparação de quantis, o conjunto de pontos obtido forma uma linha aproximadamente recta, o que nos permite supor que os dois conjuntos de quantis devem ser provenientes da distribuição normal. Neste gráfico é ainda possível identificar os dois resíduos que apresentam maior afastamento, sendo eles o terceiro resíduo, que assume o valor $e_3 = 11,8253968$, e o quinto resíduo, que assume o valor $e_5 = -6,3690476$.

- (i) – *Parâmetro a estimar:* β_1 ;
- *Nível de confiança:* $1 - \alpha = 0,95$;
- *Dimensão da amostra:* $n = 7$;
- *Variável fulcral:* $\frac{B - \beta_1}{\frac{s_{y-x}}{\sqrt{s_{xx}}}} \sim t_{n-2}$;
- *Outros dados:* $b = 14,027$, $s_{xx} = 216$ e $s_{y-x} = \sqrt{\frac{s_{yy} - b s_{xy}}{n-2}} = 7,293$;



com $-t_{n-2;1-\frac{\alpha}{2}} = -t_{5;0,975} = -2,571$ e $t_{n-2;1-\frac{\alpha}{2}} = t_{5;0,975} = 2,571$.

Logo tem-se

$$\begin{aligned} P\left[-t_{n-2;1-\frac{\alpha}{2}} < \frac{B-\beta_1}{\frac{S_{y \cdot x}}{\sqrt{S_{xx}}}} < t_{n-2;1-\frac{\alpha}{2}}\right] &= 1-\alpha \Leftrightarrow \\ \Leftrightarrow P\left[-t_{n-2;1-\frac{\alpha}{2}} \times \frac{S_{y \cdot x}}{\sqrt{S_{xx}}} < B-\beta_1 < t_{n-2;1-\frac{\alpha}{2}} \times \frac{S_{y \cdot x}}{\sqrt{S_{xx}}}\right] &= 1-\alpha \Leftrightarrow \\ \Leftrightarrow P\left[B-t_{n-2;1-\frac{\alpha}{2}} \times \frac{S_{y \cdot x}}{\sqrt{S_{xx}}} < \beta_1 < B+t_{n-2;1-\frac{\alpha}{2}} \times \frac{S_{y \cdot x}}{\sqrt{S_{xx}}}\right] &= 1-\alpha. \end{aligned}$$

Obtém-se o intervalo aleatório:


$$]I_{1-\alpha}[\beta_1 = \left] B - t_{n-2;1-\frac{\alpha}{2}} \times \frac{S_{y \cdot x}}{\sqrt{S_{xx}}}; B + t_{n-2;1-\frac{\alpha}{2}} \times \frac{S_{y \cdot x}}{\sqrt{S_{xx}}} \right[$$

e o intervalo determinista:

$$\begin{aligned}]I_{0,95}[\beta_1^* &= \left] 14,027 - 2,571 \times \frac{7,293}{\sqrt{216}}; 14,027 + 2,571 \times \frac{7,293}{\sqrt{216}} \right[= \\ &=]12,751; 15,303[. \end{aligned}$$

Estima-se que o verdadeiro declive da recta de regressão populacional se situa entre 12,751 e 15,303, com um nível de confiança de 95%, ou seja, quando o consumo aumenta um litro, a distância percorrida aumenta entre 12,751km e 15,303km.

- (j) – Parâmetro a estimar: Y_0 ;
– Nível de confiança: $1-\alpha = 0,95$;
– Dimensão da amostra: $n = 7$;
– Variável fulcral: $\frac{\hat{Y}_0 - Y_0}{S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}} \sim t_{n-2}$;
– Outros dados:
- $x_0 = 10$;
 - $\hat{y}_0 = 14,027 \times 10 - 1,953 = 138,317$;
 - $s_{xx} = 216$;
 - $\bar{x} = 9$;
 - $s_{y \cdot x} = 7,293$.



com $-t_{n-2;1-\frac{\alpha}{2}} = -t_{5;0,975} = -2,571$ e $t_{n-2;1-\frac{\alpha}{2}} = t_{5;0,975} = 2,571$.

Logo tem-se

$$\begin{aligned} P\left[-t_{n-2;1-\frac{\alpha}{2}} < \frac{\hat{Y}_0 - Y_0}{S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}} < t_{n-2;1-\frac{\alpha}{2}}\right] &= 1-\alpha \Leftrightarrow \\ \Leftrightarrow P\left[-t_{n-2;1-\frac{\alpha}{2}} \times S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}} < \hat{Y}_0 - Y_0 < \right. & \\ \left. t_{n-2;1-\frac{\alpha}{2}} \times S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}\right] &= 1-\alpha \Leftrightarrow \\ \Leftrightarrow P\left[\hat{Y}_0 - t_{n-2;1-\frac{\alpha}{2}} \times S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}} < Y_0 < \right. & \\ \left. \hat{Y}_0 + t_{n-2;1-\frac{\alpha}{2}} \times S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}\right] &= 1-\alpha. \end{aligned}$$

Obtém-se o intervalo aleatório:

$$\begin{aligned}]I_{1-\alpha}[Y_0 &= \left] \hat{Y}_0 - t_{n-2;1-\frac{\alpha}{2}} \times S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}}; \right. \\ &\quad \left. \hat{Y}_0 + t_{n-2;1-\frac{\alpha}{2}} \times S_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{S_{xx}}} \right[\end{aligned}$$

e o intervalo determinista:

$$\begin{aligned}]I_{0,95}[Y_0^* &= \left] 138,317 - 2,571 \times 7,293 \times \sqrt{1 + \frac{1}{7} + \frac{(10-9)^2}{216}}; \right. \\ &\quad \left. 138,317 + 2,571 \times 7,293 \times \sqrt{1 + \frac{1}{7} + \frac{(10-9)^2}{216}} \right[= \\ &=]118,232; 158,402[. \end{aligned}$$




Estima-se que a verdadeira estimativa de y quando $x = 10$ se situa entre 118,232 e 158,402, com um nível de confiança de 95%, ou seja, quando o consumo é de 10 litros, a distância percorrida varia entre 118,232km e 158,402km.

- (k) – Parâmetro a testar: β_1 ;
– Formulação das hipóteses:

$$\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases} \quad (\text{teste bilateral}) ;$$

- Nível de significância: $\alpha = 0,05$;
– Dimensão da amostra: $n = 7$;
– Estatística de teste: $T_0 = \frac{B - (\beta_1)_0}{\frac{s_{y-x}}{\sqrt{s_{xx}}}} \sim t_{n-2}$;
– Outros dados: $b = 14,027$, $s_{xx} = 216$ e $s_{y-x} = 7,293$;
– Determinação da região crítica e da região de aceitação:



com $-t_{n-2; 1-\frac{\alpha}{2}} = -t_{5; 0,975} = -2,571$ e $t_{n-2; 1-\frac{\alpha}{2}} = t_{5; 0,975} = 2,571$. Obtemos assim as regiões, $R.A. =]-2,571; 2,571[$ e $R.C. =]-\infty; -2,571] \cup [2,571; +\infty[$;


- Cálculo do valor da estatística de teste: $T_0 = \frac{14,027-0}{\frac{7,293}{\sqrt{216}}} = 28,267$;
– Tomada de decisão: Como o valor da estatística de teste $T_0 = 28,267$ pertence à região crítica deve-se rejeitar H_0 , ao nível de significância de 5%, ou seja, concluímos que o modelo ajustado é significativo.

- (l) – Parâmetro a testar: β_1 ;
– Formulação das hipóteses:

$$\begin{cases} H_0 : \beta_1 \geq 15 \\ H_1 : \beta_1 < 15 \end{cases} \quad (\text{teste unilateral à esquerda}) ;$$



- Nível de significância: $\alpha = 0,05$;
– Dimensão da amostra: $n = 7$;
– Estatística de teste: $T_0 = \frac{B - (\beta_1)_0}{\frac{s_{y-x}}{\sqrt{s_{xx}}}} \sim t_{n-2}$;
– Outros dados: $b = 14,027$, $s_{xx} = 216$ e $s_{y-x} = 7,293$;
– Determinação da região crítica e da região de aceitação:



com $-t_{n-2; 1-\alpha} = -t_{5; 0,95} = -2,015$. Obtemos assim as regiões, $R.C. =]-\infty; -2,015]$ e $R.A. =]-2,015; +\infty[$;

- Cálculo do valor da estatística de teste: $T_0 = \frac{14,027-15}{\frac{7,293}{\sqrt{216}}} = -1,961$;
– Tomada de decisão: Como o valor da estatística de teste $T_0 = -1,961$ pertence à região de aceitação não se deve rejeitar H_0 , ao nível de significância de 5%, ou seja, não existe evidência estatística suficiente para rejeitar a hipótese de que a distância percorrida aumenta pelo menos 15 km por cada litro a mais de consumo.


- (m) – Parâmetro a testar: β_0 ;
– Formulação das hipóteses:

$$\begin{cases} H_0 : \beta_0 = 0 \\ H_1 : \beta_0 \neq 0 \end{cases} \quad (\text{teste bilateral}) ;$$

- Nível de significância: $\alpha = 0,01$;
– Dimensão da amostra: $n = 7$;
– Estatística de teste: $T_0 = \frac{A - (\beta_0)_0}{s_{y-x} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}}} \sim t_{n-2}$;
– Outros dados: $a = -1,953$, $s_{xx} = 216$, $\bar{x} = 9$ e $s_{y-x} = 7,293$;



- Determinação da região crítica e da região de aceitação:



com $-t_{n-2, 1-\frac{\alpha}{2}} = -t_{5, 0,995} = -4,032$ e $t_{n-2, 1-\frac{\alpha}{2}} = t_{5, 0,995} = 4,032$.
Obtemos assim as regiões, $R.A. =]-4,032; 4,032[$ e $R.C. =]-\infty; -4,032] \cup [4,032; +\infty[$.

- Cálculo do valor da estatística de teste: $T_0 = \frac{-1,953-0}{7,293 \times \sqrt{\frac{1}{7} + \frac{9^2}{216}}} = -0,372$;

- Tomada de decisão: Como o valor da estatística de teste $T_0 = -0,372$ pertence à região de aceitação não se deve rejeitar H_0 , ao nível de significância de 1%, ou seja, não existe evidência estatística suficiente para rejeitar a hipótese de que verdadeira ordenada na origem da recta populacional é zero. Conclui-se que quando o consumo é nulo a distância percorrida também é nula.

(n)

- Análise do output 1:

* Modelo de regressão linear simples da distância percorrida, em km, em função do consumo de combustível, em litros.

* Estimativa para os erros $e_i = y_i - \hat{y}_i$:

$$e_1 = -6,0913; \quad e_2 = -0,1190; \quad e_3 = 11,8254;$$

$$e_4 = -4,2857; \quad e_5 = -6,3690; \quad e_6 = 5,5754;$$

$$e_7 = -0,5357.$$

* Estimativa para os coeficientes da recta de regressão populacional:

$$a = -1,9643; \quad b = 14,0278,$$

tendo-se facilmente a recta de regressão:

$$\hat{y}_i = a + bx_i = -1,9643 + 14,0278x_i.$$



- Interpretação do declive da recta, b : quando o consumo aumenta um litro, a distância percorrida aumenta 14,0278 km;
- Interpretação da ordenada na origem, a : o valor de a representa a distância percorrida quando o consumo é nulo. Neste caso esta interpretação não faz sentido porque a distância percorrida não pode ser negativa.

- * Estimativa para o desvio padrão dos estimadores dos parâmetros da recta de regressão:

$$s_A = s_{y \cdot x} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}} = 5,2612;$$

$$s_B = \frac{s_{y \cdot x}}{\sqrt{s_{xx}}} = 0,4975.$$

- * Valor da estatística de teste e do p -value para um teste de hipóteses à significância do parâmetro β_0 :

$$T_0 = \frac{a - 0}{s_{y \cdot x} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}}} = \frac{a - 0}{s_A} = -0,373;$$

$$p\text{-value} = 0,724.$$

- * Valor da estatística de teste e do p -value para um teste de hipóteses à significância do modelo:

$$T_0 = \frac{b - 0}{\frac{s_{y \cdot x}}{\sqrt{s_{xx}}}} = \frac{b - 0}{s_B} = 28,199;$$

$$p\text{-value} = 0,0000105.$$

- * A linha depois da tabela apresenta uma legenda sobre o posicionamento do valor obtido para o p -value, tendo em conta os valores usuais utilizados para o nível de significância.

- * Estimativa para o desvio padrão dos erros ou resíduos:

$$s_{y \cdot x} = \sqrt{\frac{SQE}{n-2}} = \sqrt{\frac{s_{yy} - bs_{xy}}{n-2}} = 7,311,$$

com 5 graus de liberdade.

- * Coeficiente de determinação linear amostral:

$$r^2 = \frac{SQR}{SQT} = 1 - \frac{SQE}{SQT} = \frac{s_{xy}^2}{s_{xx}s_{yy}} = 0,9938,$$



pelo que cerca de 99,38% da variabilidade da distância percorrida, em km, é explicada à custa do consumo, em litros. Tem-se facilmente o coeficiente de correlação linear amostral dado por:

$$r = \sqrt{r^2} = \sqrt{0,9938} = 0,9968952,$$

pelo que se pode concluir que existe uma correlação linear positiva quase perfeita entre as variáveis.

* Coeficiente de determinação amostral ajustado:

$$r_{ajust}^2 = 1 - \left(\frac{n-1}{n-2} \right) (1 - r^2) = 0,9925,$$

e este coeficiente dá uma ideia da proporção de variação de Y explicada pelo modelo de regressão, tendo em conta o número de variáveis independentes.

* Valor da estatística de teste para a hipótese do coeficiente de regressão ser nulo, $\beta_1 = 0$, que, no caso de se ter apenas uma variável independente, coincide com o resultado obtido para o teste t para $\beta_1 = 0$.

$$F_0 = \frac{\frac{SQR}{1}}{\frac{SQE}{n-2}} = 795,2.$$

Recorde-se que para qualquer modelo com 1 grau de liberdade, o teste F é idêntico ao quadrado do teste t , $(28,199)^2 = 795,1836$, com 1 e 5 graus de liberdade. O último valor apresentado corresponde ao p -value = 0,00000105 para este teste F . Dado que o p -value obtido para o teste t e que o p -value obtido para o teste F são iguais, a conclusão pode ser retirada da seguinte forma: como $\alpha = 0,05 \geq 0,00000105 = p$ -value, pelo que se deve rejeitar H_0 ao nível de significância de 5%, ou seja, conclui-se que o modelo ajustado é significativo.

– Análise do output 2:

* Número de graus de liberdade: 1 e 5.

* Soma de quadrados da regressão:

$$SQR = \frac{s_{xy}^2}{s_{xx}} = 42504.$$



* Soma de quadrados dos erros ou resíduos:

$$SQE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = s_{yy} - bs_{xy} = s_{yy} - \frac{s_{xy}^2}{s_{xx}} = 267.$$

Com estes dois resultados obtém-se facilmente a soma de quadrados total:

$$\begin{aligned} SQT &= SQE + SQR = 267 + 42504 = \\ &= 42771 = s_{yy}. \end{aligned}$$

* Média de quadrados da regressão:

$$MQR = \frac{SQR}{1} = 42504.$$

* Média de quadrados dos erros:

$$MQE = \frac{SQE}{n-2} = 53.$$

* Valor da estatística de teste para a hipótese do coeficiente de regressão ser nulo, $\beta_1 = 0$, que, no caso de se ter apenas uma variável independente, coincide com o resultado obtido para o teste t para $\beta_1 = 0$.

$$F_0 = \frac{MQR}{MQE} = 795,18.$$

Recorde-se que para qualquer modelo com 1 grau de liberdade, o teste F é idêntico ao quadrado do teste t , $(28,199)^2 = 795,1836$, com 1 e 5 graus de liberdade. O último valor apresentado corresponde ao p -value = 0,00000105 para este teste F . A conclusão pode ser retirada usando o p -value = 0,00000105 obtido para o teste F . Dado que se tem $\alpha = 0,05 \geq 0,00000105 = p$ -value, deve-se rejeitar H_0 ao nível de significância de 5%, ou seja, conclui-se que o modelo ajustado é significativo.

* A linha depois da tabela apresenta uma legenda sobre o posicionamento do valor obtido para o p -value, tendo em conta os valores usuais utilizados para o nível de significância.



Exercício 2.

(a) Sejam as variáveis aleatórias:

- x - “humidade relativa ambiente, em %”;
- Y - “quantidade de um determinado solvente evaporado durante a pintura, em %”.

Tem-se:

$$\bar{x} = \frac{\sum_{i=1}^{20} x_i}{20} = \frac{1050}{20} = 52,5;$$

$$\bar{y} = \frac{\sum_{i=1}^{20} y_i}{20} = \frac{190}{20} = 9,5;$$

$$s_{xx} = \sum_{i=1}^{20} x_i^2 - 20 \bar{x}^2 = 60000 - 20 \times 52,5^2 = 4875;$$

$$s_{yy} = \sum_{i=1}^{20} y_i^2 - 20 \bar{y}^2 = 2000 - 20 \times 9,5^2 = 195$$

e

$$s_{xy} = \sum_{i=1}^{20} x_i y_i - 20 \bar{x} \bar{y} = 9600 - 20 \times 52,5 \times 9,5 = -375.$$

Os coeficientes da recta de regressão são dados por:

$$b = \frac{s_{xy}}{s_{xx}} = \frac{-375}{4875} = -0,0769$$

e

$$a = \bar{y} - b\bar{x} = 9,5 + 0,0769 \times 52,5 = 13,537.$$

Obtemos assim a equação da recta de regressão:

$$\hat{y}_i = a + bx_i = 13,537 - 0,0769x_i.$$

- Interpretação do declive da recta, b : se a humidade relativa ambiente aumenta 1% então a quantidade de solvente evaporado durante a pintura diminui 0,0769%;
- Interpretação da ordenada na origem, a : quando a humidade relativa ambiente é nula, a quantidade de solvente evaporado durante a pintura é de 13,537%.



(b) Tem-se:

$$r^2 = \frac{s_{xy}^2}{s_{xx}s_{yy}} = \frac{(-375)^2}{4875 \times 195} = 0,15.$$

A qualidade do ajustamento é muito fraca pois apenas 15% da variabilidade de Y é explicada à custa desta variável x .

Exercício 3.

(a) Sejam as variáveis aleatórias:

- x - “número de cigarros fumados’ por dia”;
- Y - “anos de vida”.

Sabemos que o coeficiente de correlação linear amostral é dado por:

$$r = \frac{s_{xy}}{\sqrt{s_{xx} \times s_{yy}}}.$$

Vamos começar por calcular as médias das duas variáveis:

$$\bar{x} = \frac{\sum_{i=1}^{15} x_i}{15} = \frac{292}{15} = 19,4667$$

e

$$\bar{y} = \frac{\sum_{i=1}^{15} y_i}{15} = \frac{1103}{15} = 73,5333.$$

Tem-se então a soma de quadrados de x dada por:

$$s_{xx} = \sum_{i=1}^{15} x_i^2 - 15 \bar{x}^2 = 7840 - 15 \times 19,4667^2 = 2155,733,$$

a soma de quadrados de y dada por:

$$s_{yy} = \sum_{i=1}^{15} y_i^2 - 15 \bar{y}^2 = 1683,733$$

e a soma cruzada dada por:

$$s_{xy} = \sum_{i=1}^{15} (x_i - \bar{x})(y_i - \bar{y}) = -1356,733.$$

Assim

$$r = \frac{s_{xy}}{\sqrt{s_{xx} \times s_{yy}}} = \frac{-1356,733}{\sqrt{2155,733 \times 1683,733}} = -0,7121.$$

Podemos concluir que existe uma correlação linear amostral negativa entre as variáveis. Assim, as variáveis tendem a variar em sentidos opostos, ou seja, quando uma aumenta a outra diminui.



(b) A recta de regressão ou recta ajustada é dada por:

$$\hat{y}_i = a + bx_i.$$

Os coeficientes da recta de regressão são dados por:

$$b = \frac{s_{xy}}{s_{xx}} = \frac{-1356,733}{2155,733} = -0,6294$$

e

$$a = \bar{y} - b\bar{x} = 73,5333 + 0,6294 \times 19,4667 = 85,7849.$$

Obtemos assim a equação da recta de regressão:

$$\hat{y}_i = a + bx_i = 85,7849 - 0,6294x_i.$$

- Interpretação do declive da recta, $b = -0,6294$: Quando o número de cigarros fumados por dia aumenta um cigarro, os anos de vida diminuem 0,6294 anos;
- Interpretação da ordenada na origem, $a = 85,7849$: Quando o número de cigarros fumados por dia é zero cigarros, os anos de vida são 85,7849 anos.

(c) Tem-se:

$$r^2 = \frac{s_{xy}^2}{s_{xx} \times s_{yy}} = \frac{(-1356,733)^2}{2155,733 \times 1683,733} = 0,5071,$$

pelo que 50,71% da variabilidade dos anos de vida (Y) é explicada à custa do número de cigarros fumados por dia (x).