

Estatística Descritiva e Análise Exploratória de Dados

Unidade Curricular: Probabilidades e Estatística (LEIC) **Enquadramento:** Item 1 dos conteúdos programáticos da UC — primeiro grande tema do programa.

Objetivos de aprendizagem:

- Aplicar técnicas de **estatística descritiva** e **análise exploratória de dados (AED)** a um conjunto de dados real.
- Organizar, resumir e representar graficamente dados qualitativos e quantitativos.
- Calcular e interpretar **medidas de tendência central, dispersão, posição e forma**.
- Reconhecer padrões, anomalias (*outliers*) e relações entre variáveis como preparação para os temas seguintes da UC (probabilidade, inferência).

[*PROFUNDIDADE ASSUMIDA*] — A FUC não detalha subtópicos nem nível de aprofundamento para este item do programa; assume-se um nível **introdutório/aplicado**, coerente com um primeiro tema de uma UC de engenharia com componente computacional (cf. metodologia de ensino da FUC: "resolução de exercícios com recurso a programas computacionais").

População, Amostra e Tipos de Dados

- **População:** conjunto total de elementos sobre os quais se pretende tirar conclusões.
- **Amostra:** subconjunto representativo da população, efetivamente observado/medido.
- **Estatística descritiva** organiza e resume os dados *observados*; a **inferência estatística** (temas posteriores da UC) generaliza conclusões da amostra para a população.

Classificação das variáveis estatísticas:

- **Qualitativas (categóricas)**
 - *Nominais*: sem ordem natural (ex.: distrito de residência)
 - *Ordinais*: com ordem natural (ex.: grau de satisfação)
- **Quantitativas (numéricas)**
 - *Discretas*: valores contáveis (ex.: nº de irmãos)
 - *Contínuas*: valores num intervalo real (ex.: altura, tempo)

Exemplo de trabalho (usado ao longo dos slides seguintes): Notas (em 20 valores) de **10 alunos** num teste de avaliação: 9, 10, 11, 12, 12, 13, 14, 15, 16, 18

Organização de Dados — Tabelas de Frequências

Para resumir um conjunto de dados constrói-se uma **tabela de frequências**, com:

- **Frequência absoluta (n_i)** — número de observações de cada valor/classe
- **Frequência relativa ($f_i = n_i/n$)** — proporção de observações
- **Frequência absoluta acumulada e frequência relativa acumulada**

Nota	n_i	f_i	N_i (acum.)	F_i (acum.)
9	1	0,10	1	0,10
10	1	0,10	2	0,20
11	1	0,10	3	0,30
12	2	0,20	5	0,50
13	1	0,10	6	0,60
14	1	0,10	7	0,70
15	1	0,10	8	0,80
16	1	0,10	9	0,90
18	1	0,10	10	1,00

- Para variáveis **contínuas** ou com muitos valores distintos, agrupam-se os dados em **classes** (intervalos) de igual amplitude antes de construir a tabela.

Representação Gráfica — Dados Qualitativos

- **Gráfico de barras:** uma barra por categoria, altura proporcional à frequência. Adequado a nominais e ordinais.
- **Gráfico circular (*pie chart*):** útil para visualizar a proporção de cada categoria no total; perde eficácia com muitas categorias.
- **Diagrama de Pareto:** gráfico de barras ordenado por frequência decrescente, com linha de frequências acumuladas — destaca as categorias mais relevantes.

Boa prática: preferir gráficos de barras a gráficos circulares quando há mais de 4–5 categorias, pela maior facilidade de comparação visual. [FONTE EXTERNA]

Representação Gráfica — Dados Quantitativos

- **Histograma:** para dados contínuos/agrupados em classes; área de cada barra proporcional à frequência da classe.
 - Regra de Sturges para o número de classes: $k = 1 + 3,322 \times \log_{10}(n)$ [FONTE EXTERNA] (regra prática; nº de classes pode também ser ajustado visualmente)
- **Diagrama de ramo-e-folhas (*stem-and-leaf*):** preserva os valores individuais dos dados ao mesmo tempo que mostra a forma da distribuição — útil para amostras pequenas/moderadas.
- **Polígono de frequências:** linha que une os pontos médios de cada classe — útil para comparar várias distribuições no mesmo gráfico.

Exemplo (ramo-e-folhas das notas):

```
Ramo | Folhas
0    | 9
```

1		0 1 2 2 3 4 5 6
1		8

Medidas de Tendência Central — Média

A **média aritmética** é a medida de localização central mais usada:

$$\bar{x} = (1/n) \times \sum x_i, \quad i = 1, \dots, n$$

Cálculo com o exemplo das notas:

$$\bar{x} = (9+10+11+12+12+13+14+15+16+18) / 10 = 130 / 10 = 13,0$$

- **Vantagem:** usa toda a informação dos dados.
- **Limitação:** é **muito sensível a valores extremos (outliers)** — um único valor muito alto ou muito baixo distorce a média.
- Para dados agrupados em classes, usa-se a **média ponderada** pelos pontos médios das classes: $\bar{x} = \frac{\sum(x_i \times n_i)}{n}$

Medidas de Tendência Central — Mediana e Moda

Mediana (Md) — valor que divide os dados ordenados em duas metades iguais:

- n ímpar → valor central
- n par → média dos dois valores centrais

Cálculo com o exemplo das notas (já ordenadas, $n=10$):

dados: 9, 10, 11, 12, 12, 13, 14, 15, 16, 18
 $Md = (12 + 13) / 2 = 12,5$

Moda (Mo) — valor(es) que ocorre(m) com maior frequência. No exemplo: $Mo = 12$ (única moda, ocorre 2 vezes).

Quando usar cada medida:

- Distribuição aproximadamente simétrica, sem outliers → **média**
- Distribuição assimétrica ou com outliers → **mediana** (mais robusta)
- Dados qualitativos → apenas a **moda** faz sentido

Medidas de Dispersão — Amplitude, Variância e Desvio-Padrão

A tendência central não é suficiente — é preciso medir a **dispersão (variabilidade)** dos dados.

- **Amplitude (range):** $R = x_{\max} - x_{\min} \rightarrow$ no exemplo: $R = 18 - 9 = 9$
- **Variância amostral** (afastamento médio quadrático em relação à média):

$$s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

- **Desvio-padrão amostral:** $s = \sqrt{s^2}$ — expresso nas mesmas unidades dos dados (mais interpretável que a variância)

Cálculo com o exemplo das notas ($\bar{x} = 13$):

$$\begin{aligned}\sum (x_i - \bar{x})^2 &= (-4)^2 + (-3)^2 + (-2)^2 + (-1)^2 + (-1)^2 + 0^2 + 1^2 + 2^2 + 3^2 + 5^2 = 70 \\ s^2 &= 70 / 9 \approx 7,78 \\ s &= \sqrt{7,78} \approx 2,79\end{aligned}$$

O denominador $n - 1$ (em vez de n) é usado para que a variância amostral seja um **estimador não-enviesado** da variância populacional — propriedade explorada em maior detalhe no tema de Estimação.

Medidas de Dispersão — Coeficiente de Variação

- **Coeficiente de variação (CV):** desvio-padrão relativo à média, geralmente em percentagem:

$$CV = (s / \bar{x}) \times 100\%$$

Cálculo com o exemplo das notas:

$$CV = (2,79 / 13) \times 100\% \approx 21,5\%$$

- **Utilidade principal:** comparar a dispersão de **conjuntos de dados com unidades ou escalas diferentes** (ex.: variabilidade de notas vs. variabilidade de salários), algo que a variância e o desvio-padrão (medidas absolutas) não permitem fazer diretamente.
- Não é adequado quando $\bar{x}$ é próximo de zero ou os dados incluem valores negativos.

Medidas de Posição — Quartis e Percentis

Generalizam a ideia de mediana, dividindo os dados ordenados em partes iguais:

- **Quartis (Q1, Q2, Q3):** dividem os dados em 4 partes iguais (25% cada). $Q2 = Md$
- **Percentis (P1, ..., P99):** dividem os dados em 100 partes iguais

- **Amplitude interquartil:** $IQR = Q3 - Q1$ — mede a dispersão dos 50% centrais dos dados, sendo **robusta a outliers**

Cálculo com o exemplo das notas (metade inferior: 9, 10, 11, 12, 12 | metade superior: 13, 14, 15, 16, 18):

```
Q1 = mediana da metade inferior = 11
Q3 = mediana da metade superior = 15
IQR = Q3 - Q1 = 15 - 11 = 4
```

Nota importante: existem várias convenções de cálculo de quartis (ex.: com ou sem interpolação), pelo que softwares diferentes podem devolver valores ligeiramente distintos para o mesmo conjunto de dados.

Diagrama de Extremos e Quartis (Boxplot) e Outliers

O **boxplot** resume graficamente cinco valores: $x_{\min}$, $Q1$, Md , $Q3$, $x_{\max}$, e permite identificar **outliers** de forma sistemática.

Regra dos 1,5×IQR para deteção de outliers:

```
Limite inferior =  $Q1 - 1,5 \times IQR$ 
Limite superior =  $Q3 + 1,5 \times IQR$ 
```

Qualquer valor fora destes limites é assinalado como potencial **outlier**.

Cálculo com o exemplo das notas:

```
Limite inferior =  $11 - 1,5 \times 4 = 5$ 
Limite superior =  $15 + 1,5 \times 4 = 21$ 
```

Todos os valores (9 a 18) estão dentro de $[5, 21]$ → **não há outliers** nesta amostra.

Vantagens do boxplot: visualiza simultaneamente centro, dispersão, simetria e outliers; muito útil para **comparar várias amostras lado a lado**.

Medidas de Assimetria — Forma da Distribuição

A forma de uma distribuição complementa a informação dada por tendência central e dispersão:

- **Simétrica:** $média \approx mediana \approx moda$
- **Assimetria positiva (à direita):** cauda mais longa à direita → $média > mediana$
- **Assimetria negativa (à esquerda):** cauda mais longa à esquerda → $média < mediana$

Coeficiente de assimetria de Pearson (medida simples de referência): *[FONTE EXTERNA]*

$$As = 3 \times (\bar{x} - Md) / s$$

Interpretação no exemplo das notas:

$$As = 3 \times (13 - 12,5) / 2,79 \approx 0,54 \rightarrow \text{ligeira assimetria positiva}$$

Esta análise de forma é um primeiro indício de **não-normalidade**, relevante para a escolha de métodos estatísticos em temas posteriores da UC (ex.: testes de hipóteses).

Análise Exploratória Bivariada — Dispersão e Correlação

A AED não se limita a uma variável: é frequente explorar a **relação entre duas variáveis quantitativas**.

- **Diagrama de dispersão (*scatter plot*):** cada par (x_i, y_i) é um ponto no plano — primeira ferramenta visual para detetar relações lineares (ou não-lineares).
- **Covariância amostral:** mede o sentido (positivo/negativo) da relação linear:

$$s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$$

- **Coefficiente de correlação de Pearson:** versão **normalizada** (sem unidades, entre -1 e 1) da covariância:

$$r = s_{xy} / (s_x \times s_y)$$

Exemplo: horas de estudo (x) vs. nota obtida (y) de 6 alunos: $x = 1, 2, 3, 4, 5, 6$ e $y = 8, 10, 11, 13, 15, 17$ → $r \approx 0,996$ (correlação positiva muito forte).

Importante — fora do âmbito deste tema: este coeficiente é apenas uma **medida descritiva** de associação. O ajuste de uma reta de regressão e os testes formais sobre a relação entre variáveis são tratados no tema **Correlação e Regressão Linear**, mais à frente na UC.

Estatística Descritiva com Software (R)

A FUC refere explicitamente o uso de **programas computacionais adequados** na resolução de problemas estatísticos; a bibliografia inclui um manual orientado a R (Dalgaard, *Introductory Statistics with R*).

```
notas <- c(9, 10, 11, 12, 12, 13, 14, 15, 16, 18)

mean(notas)      # média -> 13
median(notas)    # mediana -> 12.5
sd(notas)        # desvio-padrão -> 2.79
```

```
var(notas)      # variância -> 7.78
summary(notas)  # min, Q1, mediana, média, Q3, max
quantile(notas) # quartis

hist(notas)     # histograma
boxplot(notas)  # diagrama de extremos e quartis
```

O uso de software permite validar cálculos manuais, explorar rapidamente grandes conjuntos de dados e gerar gráficos de forma reprodutível — competência explicitamente exigida nos objetivos de aprendizagem da UC.

Síntese — Pontos-Chave

- A **estatística descritiva** organiza, resume e visualiza dados; é o ponto de partida de qualquer análise estatística e antecede os temas de probabilidade e inferência da UC.
- **Tipo de variável** (qualitativa/quantitativa, discreta/contínua) determina as técnicas e gráficos adequados (barras/circular vs. histograma/ramo-e-folhas).
- **Tendência central**: média (sensível a outliers), mediana (robusta), moda.
- **Dispersão**: amplitude, variância, desvio-padrão (absolutas) e coeficiente de variação (relativa, comparável entre escalas).
- **Posição**: quartis, percentis e **IQR** — base da regra dos **1,5×IQR** para detecção de outliers e do **boxplot**.
- **Forma**: simetria/assimetria através da comparação entre média e mediana.
- **AED bivariada**: diagrama de dispersão, covariância e correlação — primeiro passo antes da regressão linear (tema futuro).
- O domínio destas ferramentas, incluindo o uso de **software estatístico**, é pré-requisito direto para os temas seguintes: Probabilidade, Variáveis Aleatórias e Inferência Estatística.