

Estatística Descritiva e Análise Exploratória de Dados

Probabilidades e Estatística | 4166

Slide 1: Introdução ao Tema

Objetivos de Aprendizagem

Após esta aula, o aluno deverá ser capaz de:

- **Organizar** e **resumir** conjuntos de dados utilizando técnicas de estatística descritiva
- **Construir** e **interpretar** tabelas de frequências e gráficos adequados a cada tipo de variável
- **Calcular** e **interpretar** medidas de localização, dispersão e forma
- **Identificar** padrões, outliers e características relevantes nos dados
- **Comunicar** resultados de forma clara e fundamentada

Este tema constitui a base para toda a análise estatística subsequente, permitindo compreender a estrutura dos dados antes de aplicar métodos inferenciais.

Slide 2: Tipos de Variáveis

Classificação fundamental

Variáveis Qualitativas (Categóricas)

- **Nominais**: categorias sem ordem intrínseca
 - Ex: sexo, cor, área científica
- **Ordinais**: categorias com ordem natural
 - Ex: nível de escolaridade, classificação (fraco/regular/bom)

Variáveis Quantitativas (Numéricas)

- **Discretas**: valores inteiros contáveis
 - Ex: número de irmãos, número de defeitos por peça
- **Contínuas**: qualquer valor num intervalo
 - Ex: altura, tempo, temperatura

A classificação correta determina as técnicas de análise apropriadas

Exemplo prático:

Considere um estudo sobre alunos de engenharia:

- Curso → Qualitativa nominal
- Ano de estudo → Qualitativa ordinal
- Número de disciplinas inscritas → Quantitativa discreta
- Nota média → Quantitativa contínua

Slide 3: Organização de Dados - Tabelas de Frequências

Tabela de Frequências para Variáveis Qualitativas

Categoria	Frequência Absoluta (n_i)	Frequência Relativa (f_i)	Frequência Percentual (%)
Categoria 1	n_1	n_1/n	$(n_1/n) \times 100$
Categoria 2	n_2	n_2/n	$(n_2/n) \times 100$
...	...	...	...
Total	n	1	100%

Tabela de Frequências para Variáveis Quantitativas (Dados Agrupados)

1. Determinar o **número de classes** (k) — regra de Sturges: $k = 1 + 3.322 \log_{10}(n)$
2. Calcular a **amplitude total**: $A = \max - \min$
3. Definir a **amplitude de classe**: $h = A/k$ (arredondar)
4. Construir os **intervalos de classe**

Classe	Frequência Absoluta	Frequência Relativa	Frequência Acumulada
$[a, b[$	n_1	f_1	$F_1 = f_1$
$[b, c[$	n_2	f_2	$F_2 = f_1 + f_2$
...	...	...	...

Slide 4: Representações Gráficas

Para Variáveis Qualitativas

Gráfico de Barras

- Representa cada categoria com uma barra
- Altura proporcional à frequência
- Adequado para comparar categorias

Gráfico de Setores (Pizza)

- Cada categoria representada por um setor circular
- Ângulo do setor = $f_i \times 360^\circ$
- Útil para visualizar proporções

Para Variáveis Quantitativas

Histograma

- Barras justapostas sem espaços
- Área de cada barra proporcional à frequência

- Base: amplitude de classe; Altura: densidade de frequência

Densidade de Frequência = Frequência / Amplitude da Classe

Diagrama de Extremos e Quartis (Boxplot)

- Representa 5 medidas: mínimo, Q1, mediana, Q3, máximo
- Identifica **outliers** (valores fora de $Q1 - 1.5 \times AIQ$ ou $Q3 + 1.5 \times AIQ$)

Slide 5: Medidas de Localização (Tendência Central)

Média Aritmética

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Vantagem:** utiliza toda a informação
- **Desvantagem:** sensível a outliers
- [FONTE EXTERNA] A média é o centro de gravidade dos dados

Mediana

- Valor que ocupa a posição central dos dados ordenados
- Se n é ímpar: valor na posição $(n+1)/2$
- Se n é par: média dos valores nas posições $n/2$ e $n/2 + 1$

A mediana é robusta — não é afetada por valores extremos

Moda

- Valor que ocorre com maior frequência
- Pode não existir ou existir mais do que uma (distribuição multimodal)

Exemplo: {2, 3, 5, 5, 7, 8, 9}

- Média = 5.57; Mediana = 5; Moda = 5

Slide 6: Medidas de Dispersão

Amplitude Total

- **A = max - min**
- Medida simples mas pouco informativa

Variância e Desvio Padrão

Variância populacional:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Variância amostral (com correção de viés):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Desvio Padrão:

$$s = \sqrt{s^2}$$

O desvio padrão mede a dispersão típica em relação à média, na mesma unidade dos dados

Amplitude Interquartil (AIQ)

- **AIQ = Q3 - Q1**
- Medida robusta de dispersão
- Representa o intervalo que contém os 50% centrais dos dados

Coefficiente de Variação (CV)

$$CV = \frac{s}{\bar{x}} \times 100\%$$

- Medida relativa de dispersão
- Útil para comparar variabilidade entre conjuntos com diferentes médias

Slide 7: Medidas de Forma

Assimetria (Skewness)

Distribuição Simétrica

- Média $\approx$ Mediana $\approx$ Moda
- Assimetria = 0

Assimetria Positiva (à direita)

- Média > Mediana > Moda
- Cauda mais longa à direita

Assimetria Negativa (à esquerda)

- Média < Mediana < Moda
- Cauda mais longa à esquerda

Coefficiente de Assimetria de Fisher:

$$g_1 = \frac{m_3}{m_2^{3/2}}$$

onde $m_k = \frac{1}{n} \sum (x_i - \bar{x})^k$

Curtose

Mede o achatamento da distribuição:

- **Mesocúrtica:** curtose ≈ 0 (distribuição normal)
- **Leptocúrtica:** curtose > 0 (caudas mais pesadas)
- **Platicúrtica:** curtose < 0 (caudas mais leves)

Estas medidas ajudam a compreender a forma da distribuição e a adequação a modelos teóricos

Slide 8: Exemplo Prático - Análise Descritiva

Dados: Notas (0-20) de 20 alunos

Dados ordenados: 8, 9, 10, 10, 11, 11, 12, 12, 12, 13, 13, 14, 14, 15, 15, 16, 16, 17, 18, 19

Medidas de Localização:

- Média = 13.35
- Mediana = $(13+13)/2 = 13$
- Moda = 12 (ocorre 3 vezes)

Medidas de Dispersão:

- Amplitude = $19 - 8 = 11$
- Desvio padrão = 2.98
- AIQ = $Q3 - Q1 = 15.5 - 11 = 4.5$

Interpretação:

- A média (13.35) é ligeiramente superior à mediana (13) → assimetria positiva ligeira
- 50% dos alunos têm nota entre 11 e 15.5
- O desvio típico de 2.98 indica variação moderada

Slide 9: Boxplot e Identificação de Outliers

Construção do Boxplot para o Exemplo

- **Mínimo** = 8
- **Q1** = 11 (posição 5.25)
- **Mediana** = 13
- **Q3** = 15.5 (posição 15.75)
- **Máximo** = 19

Identificação de Outliers

Limites para outliers:

- Limite inferior = $Q1 - 1.5 \times AIQ = 11 - 1.5 \times 4.5 = 4.25$
- Limite superior = $Q3 + 1.5 \times AIQ = 15.5 + 1.5 \times 4.5 = 22.25$

Nenhum valor fora destes limites → sem outliers

Interpretação do Boxplot:

- Caixa contém 50% dos dados (entre Q1 e Q3)
- Linha central (mediana) divide a caixa em 25% para cada lado
- Bigodes estendem-se até ao valor mais extremo não outlier

Slide 10: Análise Exploratória com Software

Utilização de R

```
# Dados de exemplo
notas <- c(8, 9, 10, 10, 11, 11, 12, 12, 12, 13, 13, 14, 14, 15, 15, 16, 16, 17,
18, 19)

# Medidas descritivas
summary(notas)
sd(notas)
IQR(notas)

# Histograma
hist(notas, main = "Histograma das Notas", xlab = "Nota",
     col = "lightblue", border = "black")

# Boxplot
boxplot(notas, main = "Boxplot das Notas", ylab = "Nota",
       col = "lightgreen")

# Cálculo de assimetria (pacote moments necessário)
library(moments)
skewness(notas)
kurtosis(notas)
```

Interpretação dos Resultados

- O histograma permite visualizar a forma da distribuição
- O boxplot identifica visualmente a presença de outliers
- As medidas numéricas complementam a análise gráfica

A combinação de métodos gráficos e numéricos é essencial para uma análise exploratória completa

Slide 11: Aplicação Prática - Caso de Estudo

Contexto: Controlo de Qualidade

Uma fábrica produz parafusos com comprimento nominal de 50 mm. Foram medidas 100 peças.

Objetivos da análise descritiva:

1. **Caraterizar** a produção atual

2. **Identificar** se há desvios sistemáticos
3. **Detetar** peças fora do esperado (outliers)
4. **Avaliar** a variabilidade do processo

Procedimentos:

```
# Simulação de dados (exemplo)
set.seed(123)
comprimentos <- rnorm(100, mean = 50.2, sd = 1.5)

# Análise descritiva
summary(comprimentos)
sd(comprimentos)

# Identificação de valores atípicos
boxplot(comprimentos)
# Limites de controlo: média ± 3×desvio padrão
```

Interpretação Esperada

- Se a média se afasta do valor nominal (50 mm), pode indicar descalibração
- Elevado desvio padrão sugere falta de controlo do processo
- Outliers indicam peças com defeitos graves

Slide 12: Síntese e Pontos-Chave

Resumo do Tema

1. Caracterização dos dados

- Classificar variáveis (qualitativas vs. quantitativas)
- Construir tabelas de frequências adequadas

2. Visualização

- Gráficos de barras e setores (qualitativas)
- Histogramas (quantitativas contínuas)
- Boxplots (identificação de outliers e comparação)

3. Medidas Resumo

- **Localização:** média, mediana, moda
- **Dispersão:** desvio padrão, AIQ, amplitude
- **Forma:** assimetria, curtose

4. Análise Integrada

- Combinar métodos numéricos e gráficos
- Interpretar resultados no contexto do problema

- Preparar dados para análises inferenciais posteriores

A estatística descritiva é a **primeira etapa** essencial em qualquer análise de dados, fornecendo a base para decisões informadas.

Referências Bibliográficas

Principais Fontes Consultadas

1. Dalgaard, P. (2014). *Introductory Statistics with R*. Springer.
2. Montgomery, D. & Runger, G. (2013). *Applied Statistics and Probability for Engineering* (6th ed.). Wiley.
3. Murteira, B. et al. (2015). *Introdução à Estatística* (3ª ed.). Escolar Editora.
4. Pedrosa, A. & Gama, S. (2016). *Introdução Computacional à Probabilidade e Estatística*. Porto Editora.
5. Pestana, D. & Velosa, S. (2008). *Introdução à Probabilidade e à Estatística*, vol. I. Fundação Calouste Gulbenkian.
6. Reis, E. et al. (2015). *Estatística Aplicada - volumes I e II* (6ª ed.). Edições Sílabo.