

Estatística Descritiva e Análise Exploratória de Dados

Introdução ao Tema

Objetivos de Aprendizagem:

- Compreender os conceitos fundamentais de **estatística descritiva** e sua importância na análise de dados.
 - Aplicar técnicas de **análise exploratória de dados (EDA)** para extrair insights significativos.
 - Interpretar resultados de medidas de tendência central, dispersão e formas de distribuição.
 - Utilizar ferramentas computacionais (ex: Python com **pandas** e **matplotlib**) para realizar EDA.
-

O que é Estatística Descritiva?

- **Definição:** Ramo da estatística que **descreve, resume e organiza** dados de uma amostra ou população.
 - **Objetivo:** Fornecer uma **visão geral** dos dados sem inferir conclusões sobre uma população maior.
 - **Componentes principais:**
 - **Medidas de tendência central:** Média, mediana, moda.
 - **Medidas de dispersão:** Amplitude, variância, desvio padrão, quartis.
 - **Medidas de forma:** Assimetria e curtose.
 - **Representações gráficas:** Histogramas, boxplots, scatter plots.
-

Medidas de Tendência Central

1. Média (Mean)

- **Fórmula:**

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

onde x_i são os valores e n é o número de observações.

- **Interpretação:** Representa o **valor médio** de um conjunto de dados.
- **Limitações:** Sensível a **outliers** (valores extremos).

2. Mediana (Median)

- **Definição:** Valor que **divide o conjunto de dados ao meio** (50% dos dados estão abaixo e 50% acima).
- **Vantagem:** **Robusta a outliers.**
- **Cálculo:**
 - Se n for ímpar: valor central.
 - Se n for par: média dos dois valores centrais.

3. Moda (Mode)

- **Definição:** Valor mais frequente no conjunto de dados.
 - **Aplicação:** Útil para dados **categóricos** ou discretos.
-

Medidas de Dispersão

1. Amplitude (Range)

- **Fórmula:**

undefined

- **Interpretação:** Medida da **variabilidade** em torno da média.

3. Desvio Padrão (Standard Deviation)

- **Fórmula:**

$$s = \sqrt{s^2}$$

- **Interpretação:** Raiz quadrada da **variância**, na mesma unidade dos dados.

4. Quartis (Quartiles)

- **Definição:** Valores que dividem os dados em **4 partes iguais** (Q1, Q2=Mediana, Q3).
 - **Aplicação:** Usados em **boxplots** para identificar outliers.
-

Medidas de Forma

1. Assimetria (Skewness)

- **Definição:** Medida da **assimetria** da distribuição.
 - **Assimetria positiva:** Cauda à direita (ex: distribuição de rendimentos).
 - **Assimetria negativa:** Cauda à esquerda (ex: idade de reformados).
 - **Simétrica:** Assimetria ≈ 0 (ex: distribuição normal).

2. Curtose (Kurtosis)

- **Definição:** Medida do **achatamento** da distribuição.
 - **Leptocúrtica:** Curtose > 0 (pico mais agudo).
 - **Mesocúrtica:** Curtose ≈ 0 (ex: distribuição normal).
 - **Platicúrtica:** Curtose < 0 (pico mais achatado).
-

Representações Gráficas

1. Histograma

- **Objetivo:** Visualizar a **distribuição de frequências** de uma variável contínua.
- **Exemplo (Python):**

```
import matplotlib.pyplot as plt
import pandas as pd

data = pd.read_csv("dados.csv")
plt.hist(data["coluna"], bins=20, color="skyblue", edgecolor="black")
plt.title("Histograma da Variável X")
plt.xlabel("Valores")
plt.ylabel("Frequência")
plt.show()
```

2. Boxplot (Diagrama de Caixa)

- **Objetivo:** Resumir a **distribuição** dos dados (mediana, quartis, outliers).
- **Exemplo (Python):**

```
import seaborn as sns

sns.boxplot(x=data["coluna"])
plt.title("Boxplot da Variável X")
plt.show()
```

3. Scatter Plot (Dispersão)

- **Objetivo:** Visualizar a **relação entre duas variáveis**.
- **Exemplo (Python):**

```
plt.scatter(data["x"], data["y"], alpha=0.5)
plt.title("Relação entre X e Y")
plt.xlabel("X")
plt.ylabel("Y")
plt.show()
```

Análise Exploratória de Dados (EDA)

Passos para uma EDA Eficaz

1. **Coleta de Dados:** Garantir que os dados estão **completos e limpos**.
2. **Limpeza de Dados:** Tratar valores em falta (NaN), outliers e inconsistências.
3. **Exploração Inicial:**
 - Resumo estatístico (`data.describe()` em Python).
 - Visualização de distribuições e correlações.
4. **Identificação de Padrões:**

- Correlações entre variáveis (`data.corr()`).
 - Tendências temporais (se aplicável).
5. **Interpretação:** Extrair **insights acionáveis** para tomada de decisão.
-

Exemplo Prático: EDA em Python

Conjunto de Dados: `iris` (Dataset Clássico)

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Carregar dados
iris = sns.load_dataset("iris")

# Resumo estatístico
print(iris.describe())

# Histograma das variáveis
iris.hist(bins=20, figsize=(10, 8))
plt.suptitle("Distribuição das Variáveis no Dataset Iris")
plt.show()

# Boxplot por espécie
sns.boxplot(data=iris, x="species", y="sepal_length")
plt.title("Comprimento da Sépala por Espécie")
plt.show()

# Matriz de correlação
corr_matrix = iris.corr(numeric_only=True)
sns.heatmap(corr_matrix, annot=True, cmap="coolwarm")
plt.title("Matriz de Correlação")
plt.show()
```

Síntese: Pontos-Chave

- **Estatística Descritiva:** Ferramenta para **resumir e descrever** dados.
 - **Medidas Fundamentais:**
 - Tendência central: **Média, mediana, moda.**
 - Dispersão: **Amplitude, variância, desvio padrão, quartis.**
 - Forma: **Assimetria e curtose.**
 - **Visualização:** **Histogramas, boxplots, scatter plots** são essenciais para EDA.
 - **EDA:** Processo **iterativo** para explorar, limpar e interpretar dados.
 - **Ferramentas Computacionais:** Python (`pandas`, `matplotlib`, `seaborn`) é amplamente utilizado.
-

Referências Bibliográficas (FUC)

1. P. Dalgaard, *Introductory Statistics with R*, Springer, 2014. [FONTE EXTERNA] (Exemplos em R, mas conceitos aplicáveis a Python).
 2. D. Pestana, S. Velosa, *Introdução à Probabilidade e à Estatística*, Fundação Calouste Gulbenkian, 2008. [FONTE EXTERNA] (Aborda estatística descritiva em detalhe).
 3. A. Pedrosa, S. Gama, *Introdução Computacional à Probabilidade e Estatística*, Porto Editora, 2016. [FONTE EXTERNA] (Inclui aplicações práticas com software).
-

Observações Finais

- **Nível de Profundidade:** Introdutório, alinhado com os objetivos da UC de **Probabilidades e Estatística** do ISEL.
- **Aplicação Prática:** Os exemplos em Python são **diretamente aplicáveis** em projetos de ciência de dados.
- **Próximos Passos:** Explorar **inferência estatística** e **testes de hipóteses** para complementar este tema.